Slide Set 2
Distribuzioni Univariate

Pietro Coretto
pcoretto@unisa.it

Corso di

Analisi e Visualizzazione dei Dati (Parte I)

Corso di Laurea in "Statistica per i Big Data" (L-41)
Università degli Studi di Salerno

Versione: 22 febbraio 2022 (h10:17)

Notes

Il punto di partenza dell'analisi è sempre un data set più o meno complesso. Nella maggior parte dei casi esso ha la forma di un 2D-array, detta anche *matrice dei dati*:

faminc	cigtax	cigprice	bwght	fatheduc	motheduc	parity	male	white	cigs	lbwght	bwghtlbs	packs	lfaminc
13.5	16.5	122.3	109	12	12	1	1	1	0	4.6913481	6.8125	0	2.60269
7.5	16.5	122.3	133	6	12	2	1	0	0	4.8903489	8.3125	0	2.0149031
0.5	16.5	122.3	129		12	2	0	0	0	4.8598118	8.0625	0	-0.693147
15.5	16.5	122.3	126	12	12	2	1	0	0	4.8362818	7.875	0	2.74084
27.5	16.5	122.3	134	14	12	2	1	1	0	4.89784	8.375	0	3.3141861
7.5	16.5	122.3	118	12	14	6	1	0	0	4.7706852	7.375	0	2.0149031
65	16.5	122.3	140	16	14	2	0	1	0	4.9416418	8.75	0	4.174387
27.5	16.5	122.3	86	12	14	2	0	0	0	4.4543471	5.375	0	3.3141861
27.5	16.5	122.3	121	12	17	2	0	1	0	4.7957911	7.5625	0	3.3141861
37.5	16.5	122.3	129	16	18	2	0	1	0	4.8598118	8.0625	0	3.624341
27.5	16.5	122.3	101	12	16	2	1	0	0	4.6151199	6.3125	0	3.3141861
27.5	16.5	122.3	133	16	15	1	1	1	0	4.8903489	8.3125	0	3.3141861
6.5	16.5	122.3	61		12	3	1	0	0	4.1108742	3.8125	0	1.871802
10.5	16.5	122.3	104	12	12	1	1	1	0	4.6443911	6.5	0	2.3513751
12.5	16.5	122.3	92	7	12	1	1	0	0	4.5217891	5.75	0	2.5257289
17.5	16.5	122.3	122	13	13	1	1	1	0	4.8040209	7.625	0	2.862201
42.5	16.5	122.3	159	18	16	1	1	1	0	5.0689039	9.9375	0	3.7495041
4.5	16.5	122.3	154		11	1	0	0	0	5.036952	9.625	0	1.504077
32.5	16.5	122.3	120	16	16	1	1	0	0	4.7874918	7.5	0	3.48124
6.5	16.5	122.3	138		11	2	0	0	0	4.9272542	8.625	0	1.871802
47.5	16.5	122.3	127	16	17	1	0	1	0	4.8441868	7.9375	0	3.8607299
22.5	16.5	122.3	107	12	12	2	1	1	0	4.6728292	6.6875	0	3.1135149
15.5	16.5	122.3	129	8	11	2	1	1	6	4.8598118	8.0625	0.3	2.74084
13.5	16.5	122.3	129	12	12	1	0	0	0	4.8598118	8.0625	0	2.60269
37.5	16.5	122.3	156	11	11	1	0	1	0	5.0498562	9.75	0	3.624341

Descrizione: http://www.decg.it/pcoretto/datasets/bwght_README.txt

Notes

Analisi dei dati univariata

Analisi univariata
studia le proprietà statistiche dei dati analizzando una variabile/feature alla volta. Essa non prende in considerazione le relazioni tra le variabili.

Domande:

- Esiste un valore di `bwght` tale da sintetizzare il complesso dei dati osservati?
- Se esiste questo valore, quanto è rappresentativo per tutte le unità nel campione?
- Vi sono campioni con valori "*anomali*" rispetto alla maggioranza?
- ...

Notes

Nozione intuitiva di distribuzione

L'oggetto "*atomico*" dell'analisi dei dati, e della statistica, è la nozione di distribuzione

Prima di tutto impareremo a caratterizzare distribuzioni univariate (DU), ovvero iniziamo a guardare il data set studiano le variabili singolarmente

Dal punto di vista matematico la nozione di DU sarà formalizzata in corsi successivi. Qui lavoreremo sulla nozione intuitiva/operativa

Una DU è un oggetto complesso determinato da una collezione di dati osservati. Per DU si intende il modo in cui questi dati si *posizionano* lungo l'intervallo/range dei valori osservati

Notes

Notazione

- n: dimensione campionaria, numero di unità statistiche osservate (n è il numero di righe del data set in forma matriciale)
- X: variabile di interesse osservata. Solitamente una colonna del data set (in forma matriciale)
- $i = 1, 2, \ldots, n$: indice che identifica le unità statistiche (righe della matrice dei dati)
- x_i: è il livello/label di X sulla i-ma unità statistica
- Per *raw data* intendiamo il set di dati osservati

$$\{x_1, x_2, \ldots, x_n\}$$

  essi corrispondono ai valori lungo la colonna X della matrice dei dati
- Indichiamo con

$$\begin{aligned} x_{\min} &= \min\{x_1, x_2, \ldots, x_n\} \\ x_{\max} &= \max\{x_1, x_2, \ldots, x_n\} \end{aligned}$$

  Il range dei dati (se numerici) è l'intervallo $[x_{\min}, x_{\max}]$

Notes

Iniziamo dalla nozione intuitiva di DU. Per adesso si assume che X sia numerica

Per DU di X intendiamo il *modo* in cui questi n livelli/labels osservati della X si distribuiscono lungo il range dei dati osservati

Una prima e semplicissima visualizzazione della distribuzione di X è lo *stripchart*:

- determino il range dei dati
- rappresento ogni punto osservato x_i su un segmento che copre il range dei dati

Notes

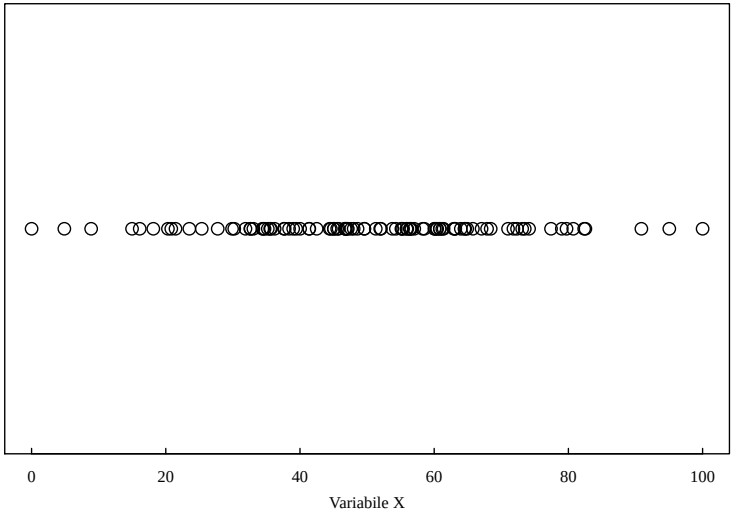

Notes

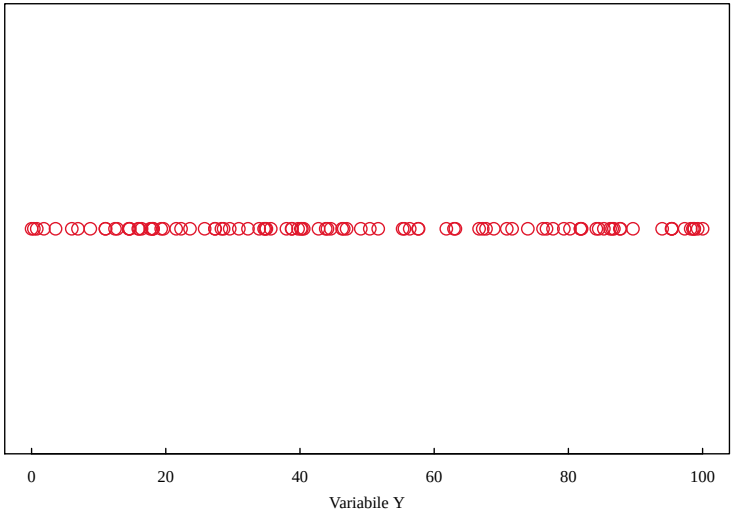

Notes

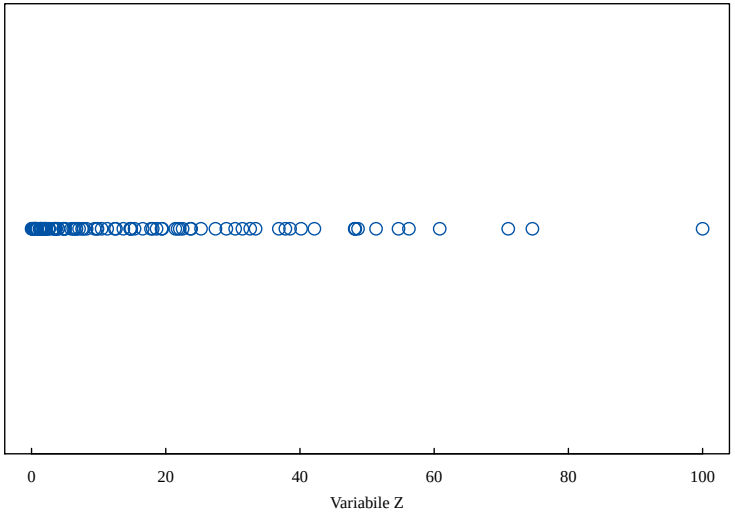

Notes

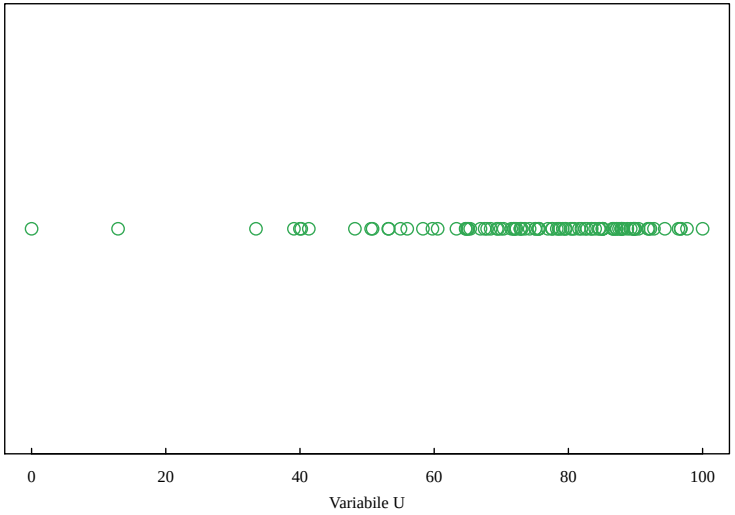

Notes

Aspetti rilevanti di una DU

- Locazione/posizione/centralità: esiste un valore *rappresentativo*? Se questo valore esiste abbiamo identificato la *parte centrale* della distribuzione. I dati lontano dal centro li chiamiamo *code della distribuzione*
- Dispersione/scatter: quanto sono dispersi i dati?
- Simmetria: esiste un punto all'interno del range rispetto al quale la *massa* di dati si dispone in modo speculare?
- Curtosi: vi sono molti dati osservati lontano dalla parte centrale (ovvero nelle code)?
- Densità: se concentriamo l'attenzione *localmente* in un punto x_0 del range, la massa di dati in quel punto quanto è *densa* di valori osservati?
- Outliers: esistono valori atipici/anomali? Esistono valori molto diversi dalla maggioranza dei punti osservati?

Notes

Frequenze relative ed assolute

Sia X una variabile che rileviamo nel campione con K livelli/labels distinti $\{x_1, x_2, \ldots, x_K\}$, definiamo:

n_k è frequenza assoluta del livello/label x_k
questo è il numero di volte che $X = x_k$ compare nei dati osservati

$f_k = \frac{n_k}{n}$ è frequenza relativa del livello/label x_k
questo è un numero in [0,1] che esprime la porzione di campioni osservati per i quali $X = x_k$.

Nota: posso esprimere le frequenze relative in termini percentuali come $f_k = \frac{n_k}{n} \times 100$

Per costruzione

- $\sum_{k=1}^{K} n_k = n$
- $\sum_{k=1}^{K} f_k = 1$

Notes

Esempio 1
Su $n = 5$ unità si osserva $X =$*sesso*, i dati osservati sono

$$\{\texttt{F}, \quad \texttt{F}, \quad \texttt{M}, \quad \texttt{F}, \quad \texttt{F}\}$$

In questo caso abbiamo $K = 2$ labels distinti: $x_1 = \texttt{F}, x_2 = \texttt{M}$. Le frequenze assolute sono

$$n_1 = 4, \quad n_2 = 1, \quad f_1 = \frac{4}{5} = 0.8, \quad f_2 = \frac{1}{5} = 0.2$$

Esempio 2
Su $n = 6$ unità si osserva $Y =$*numero di scarpe*, i dati osservati sono

$$\{38, \quad 40, \quad 40, \quad 39, \quad 38, \quad 40\}$$

In questo caso abbiamo $K = 3$ livelli distinti: $x_1 = 38, x_2 = 39, x_3 = 40$.
Le frequenze assolute sono

$$n_1 = 2, \quad n_2 = 1, \quad n_3 = 3$$

$$f_1 = \frac{2}{6} = 0.33, \quad f_2 = \frac{1}{6} = 0.17, \quad f_3 = \frac{3}{6} = 0.5$$

Notes

Possiamo calcolare le frequenze in questo modo per qualsiasi tipo di variabile? Pensiamo al caso in cui X è continua

Consideriamo la variabile X=`lfaminc` nel data set *bwght*. ci sono 27 diversi livelli osservati, molti di essi estremamente simili tra di loro. I primi valori osservati sono

$$2.6026900, \quad 2.0149031, \quad -0.6931472, \quad 2.7408400, \quad 3.3141861, \ldots$$

Dividiamo il range in K intervalli di livelli (anche detti classi di livelli o bins), e calcolo le frequenze rispetto al numero di osservazioni in ogni classe di livello.

Questo metodo appartiene ad una classe più generale di *metodi di windowing*: i dati vengono divisi e analizzati in tante piccole *finestre*.

Notes

Problema: come determino queste classi di valori? Approcci:

- Scelgo gli intervalli in modo discrezionale
- Fisso Δ, l'ampiezza dell'intervallo, e determino K di conseguenza
- Fisso K e determino l'ampiezza Δ

Esistono regole *ottimali* per ottenere classi di ampiezza uniforme. Ad esempio il metodo di *Sturge*:

- $K = 1 + \left\lceil \log_2(n) \right\rceil$
- $\Delta = \frac{x_{\max} - x_{\min}}{K}$
- Primo intervallo $\rightarrow [x_{\min}\ ,\ x_{\min} + \Delta]$
  Secondo intervallo $\rightarrow (x_{\min} + \Delta\ ,\ x_{\min} + 2\Delta]$
  ...
  k-esimo intervallo $\rightarrow (\ x_{\min} + (k-1)\Delta\ ,\ x_{\min} + k\Delta\ ]$

Esempi/Applicazioni $\longrightarrow$ `R` script file

Notes

Se K non è troppo grande, le frequenze consentono di ottenere una presentazione compatta della distribuzione dei dati

Distribuzione semplice

X	n_i	f_i
x_1	n_1	f_1
x_2	n_2	f_2
$\vdots$	$\vdots$	$\vdots$
x_K	n_K	f_K
	n	1

Distribuzione in classi

X	n_i	f_i
$x_0 \mid - \mid x_1$	n_1	f_1
$x_1 \ - \mid x_2$	n_2	f_2
$\vdots$	$\vdots$	$\vdots$
$x_{K-1} \ - \mid x_K$	n_K	f_K
	n	1

- X è quantitativo, discreto, ed espresso con troppi livelli distinti: potrebbe avere senso a costruire le classi
- ⚠ la suddivisione in classi produce perdita di informazione

Notes

Esempio: consideriamo la variabile (continua) `faminc` dal data set `bwght`. Prendiamo $K = 3$ classi uniformi:

`famic` [$10^3\times$ USD]	n_i	$f_i(\%)$
$[0.435, 22]$	526	37.9
$(22, 43.5]$	602	43.4
$(43.5, 65.1]$	260	18.7
	1388	100

Notes

Esempio: consideriamo la variabile (categoriale/nominale) `male` dal data set `bwght`.

`male`	n_i	$f_i(\%)$
Femmina (=0)	665	47.9
Maschio (=1)	723	52.1
	1388	100

Esempi/Applicazioni $\longrightarrow$ R script file

Notes

Rappresentazioni grafiche di DU

Grafico	Tipo di variabile				
	Continua	In Classi(*)	Discreta(*)	Ordinale	Nominale
stripchart	+	no	no	no	no
barplot	no	no	+	+	+
piechart	no	no	ni	+	+
istogramma	no	+	no	no	no

Nota (*):

- "*In Classi*" include il caso delle variabili continue trasformate in classi, e le variabili discrete che sono espresse con troppi livelli distinti.
- "*Discreta*" include il caso di variabili discrete con un numero ragionevole di livelli distinti.

Esempi/Applicazioni $\longrightarrow$ `R` **script file** (stripchart, barplot, piechart)

Notes

Notes