# Slide Set 2
# Distribuzioni Univariate

**Pietro Coretto**
pcoretto@unisa.it

**Corso di**

## Analisi e Visualizzazione dei Dati (Parte I)

Corso di Laurea in "Statistica per i Big Data" (L-41)
Università degli Studi di Salerno

Versione: 9 marzo 2021 (h15:22)



Notes

Il punto di partenza dell'analisi è sempre un data set più o meno complesso. Nella maggior parte dei casi esso ha la forma di un 2D-array, detta anche *matrice dei dati*:

| faminc | cigtax | cigprice | bwght | fatheduc | motheduc | parity | male | white | cigs | lbwght | bwghtlbs | packs | lfaminc |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 13.5 | 16.5 | 122.3 | 109 | 12 | 12 | 1 | 1 | 1 | 0 | 4.6913481 | 6.8125 | 0 | 2.60269 |
| 7.5 | 16.5 | 122.3 | 133 | 6 | 12 | 2 | 1 | 0 | 0 | 4.8903489 | 8.3125 | 0 | 2.0149031 |
| 0.5 | 16.5 | 122.3 | 129 | | 12 | 2 | 0 | 0 | 0 | 4.8598118 | 8.0625 | 0 | -0.693147 |
| 15.5 | 16.5 | 122.3 | 126 | 12 | 12 | 2 | 1 | 0 | 0 | 4.8362818 | 7.875 | 0 | 2.74084 |
| 27.5 | 16.5 | 122.3 | 134 | 14 | 12 | 2 | 1 | 1 | 0 | 4.89784 | 8.375 | 0 | 3.3141861 |
| 7.5 | 16.5 | 122.3 | 118 | 12 | 14 | 6 | 1 | 0 | 0 | 4.7706852 | 7.375 | 0 | 2.0149031 |
| 65 | 16.5 | 122.3 | 140 | 16 | 14 | 2 | 0 | 1 | 0 | 4.9416418 | 8.75 | 0 | 4.174387 |
| 27.5 | 16.5 | 122.3 | 86 | 12 | 14 | 2 | 0 | 0 | 0 | 4.4543471 | 5.375 | 0 | 3.3141861 |
| 27.5 | 16.5 | 122.3 | 121 | 12 | 17 | 2 | 0 | 1 | 0 | 4.7957911 | 7.5625 | 0 | 3.3141861 |
| 37.5 | 16.5 | 122.3 | 129 | 16 | 18 | 2 | 0 | 1 | 0 | 4.8598118 | 8.0625 | 0 | 3.624341 |
| 27.5 | 16.5 | 122.3 | 101 | 12 | 16 | 2 | 1 | 0 | 0 | 4.6151199 | 6.3125 | 0 | 3.3141861 |
| 27.5 | 16.5 | 122.3 | 133 | 16 | 15 | 1 | 1 | 1 | 0 | 4.8903489 | 8.3125 | 0 | 3.3141861 |
| 6.5 | 16.5 | 122.3 | 61 | | 12 | 3 | 1 | 0 | 0 | 4.1108742 | 3.8125 | 0 | 1.871802 |
| 10.5 | 16.5 | 122.3 | 104 | 12 | 12 | 1 | 1 | 1 | 0 | 4.6443911 | 6.5 | 0 | 2.3513751 |
| 12.5 | 16.5 | 122.3 | 92 | 7 | 12 | 1 | 1 | 0 | 0 | 4.5217891 | 5.75 | 0 | 2.5257289 |
| 17.5 | 16.5 | 122.3 | 122 | 13 | 13 | 1 | 1 | 1 | 0 | 4.8040209 | 7.625 | 0 | 2.862201 |
| 42.5 | 16.5 | 122.3 | 159 | 18 | 16 | 1 | 1 | 1 | 0 | 5.0689039 | 9.9375 | 0 | 3.7495041 |
| 4.5 | 16.5 | 122.3 | 154 | | 11 | 1 | 0 | 0 | 0 | 5.036952 | 9.625 | 0 | 1.504077 |
| 32.5 | 16.5 | 122.3 | 120 | 16 | 16 | 1 | 1 | 0 | 0 | 4.7874918 | 7.5 | 0 | 3.48124 |
| 6.5 | 16.5 | 122.3 | 138 | | 11 | 2 | 0 | 0 | 0 | 4.9272542 | 8.625 | 0 | 1.871802 |
| 47.5 | 16.5 | 122.3 | 127 | 16 | 17 | 1 | 0 | 1 | 0 | 4.8441868 | 7.9375 | 0 | 3.8607299 |
| 22.5 | 16.5 | 122.3 | 107 | 12 | 12 | 2 | 1 | 1 | 0 | 4.6728292 | 6.6875 | 0 | 3.1135149 |
| 15.5 | 16.5 | 122.3 | 129 | 8 | 11 | 2 | 1 | 1 | 6 | 4.8598118 | 8.0625 | 0.3 | 2.74084 |
| 13.5 | 16.5 | 122.3 | 129 | 12 | 12 | 1 | 0 | 0 | 0 | 4.8598118 | 8.0625 | 0 | 2.60269 |
| 37.5 | 16.5 | 122.3 | 156 | 11 | 11 | 1 | 0 | 1 | 0 | 5.0498562 | 9.75 | 0 | 3.624341 |

Descrizione: http://www.decg.it/pcoretto/datasets/bwght_README.txt



Notes

## Analisi dei dati univariata

Analisi univariata
studia le proprietà statistiche dei dati analizzando una variabile/feature alla volta. Essa non prende in considerazione le relazioni tra le variabili.

Domande:

- Esiste un valore di `bwght` tale da sintetizzare il complesso dei dati osservati?
- Se esiste questo valore, quanto è rappresentativo per tutte le unità nel campione?
- Vi sono campioni con valori "*anomali*" rispetto alla maggioranza?
- ...



Notes

## Nozione intuitiva di distribuzione

L'oggetto "*atomico*" dell'analisi dei dati, e della statistica, è la nozione di distribuzione

Prima di tutto impareremo a caratterizzare distribuzioni univariate (DU), ovvero iniziamo a guardare il data set studiano le variabili singolarmente

Dal punto di vista matematico la nozione di DU sarà formalizzata in corsi successivi. Qui lavoreremo sulla nozione intuitiva/operativa

Una DU è un oggetto complesso determinato da una collezione di dati osservati. Per DU si intende il modo in cui questi dati si *posizionano* lungo l'intervallo/range dei valori osservati



Notes

## Notazione

- $n$: dimensione campionaria, numero di unità statistiche osservate ($n$ è il numero di righe del data set in forma matriciale)
- $X$: variabile di interesse osservata. Solitamente una colonna del data set (in forma matriciale)
- $i = 1, 2, \ldots, n$: indice che identifica le unità statistiche (righe della matrice dei dati)
- $x_i$: è il livello/label di $X$ sulla $i$-ma unità statistica
- Per *raw data* intendiamo il set di dati osservati

$$\{x_1, x_2, \ldots, x_n\}$$

  essi corrispondono ai valori lungo la colonna $X$ della matrice dei dati
- Indichiamo con

$$x_{\min} = \min\{x_1, x_2, \ldots, x_n\}$$
$$x_{\max} = \max\{x_1, x_2, \ldots, x_n\}$$

  Il range dei dati (se numerici) è l'intervallo $[x_{\min}, x_{\max}]$



Notes

Iniziamo dalla nozione intuitiva di DU. Per adesso si assume che $X$ sia numerica

Per DU di $X$ intendiamo il *modo* in cui questi $n$ livelli/labels osservati della $X$ si distribuiscono lungo il range dei dati osservati

Una prima e semplicissima visualizzazione della distribuzione di $X$ è lo *stripchart*:

- determino il range dei dati
- rappresento ogni punto osservato $x_i$ su un segmento che copre il range dei dati



Notes

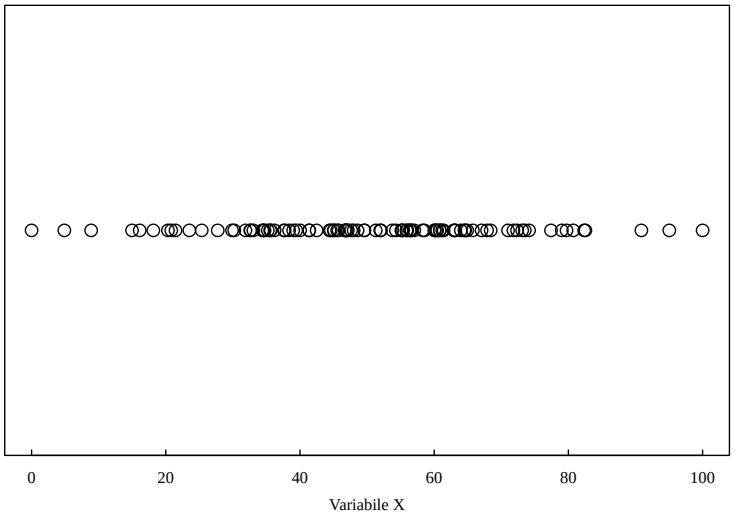




Notes

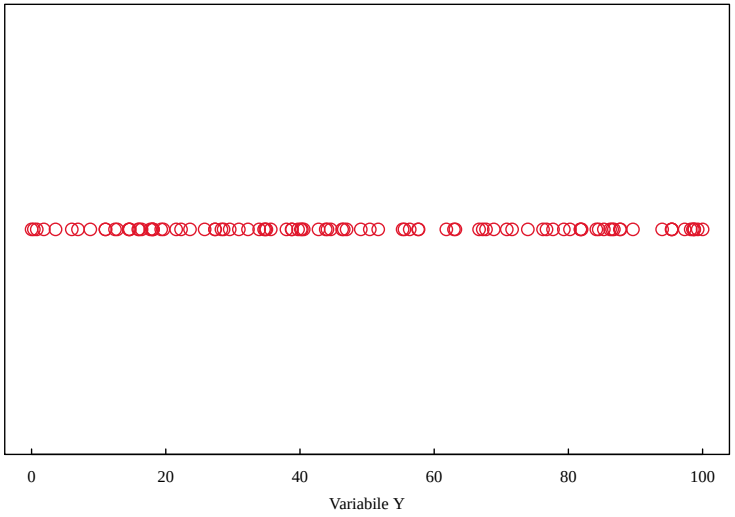




Notes

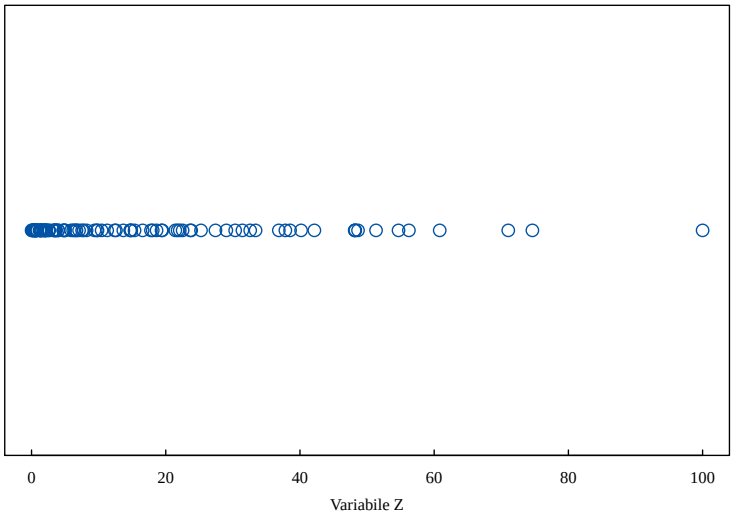




Notes

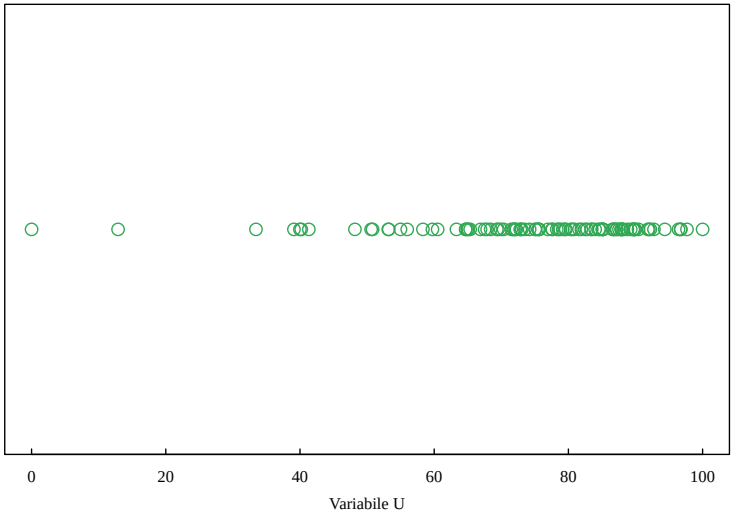




Notes

## Aspetti rilevanti di una DU

- Locazione/posizione/centralità: esiste un valore *rappresentativo*? Se questo valore esiste abbiamo identificato la *parte centrale* della distribuzione. I dati lontano dal centro li chiamiamo *code della distribuzione*
- Dispersione/scatter: quanto sono dispersi i dati?
- Simmetria: esiste un punto all'interno del range rispetto al quale la *massa* di dati si dispone in modo speculare?
- Curtosi: vi sono molti dati osservati lontano dalla parte centrale (ovvero nelle code)?
- Densità: se concentriamo l'attenzione *localmente* in un punto $x_0$ del range, la massa di dati in quel punto quanto è *densa* di valori osservati?
- Outliers: esistono valori atipici/anomali? Esistono valori molto diversi dalla maggioranza dei punti osservati?



Notes

## Frequenze relative ed assolute

Sia $X$ una variabile che rileviamo nel campione con $K$ livelli/labels distinti $\{x_1, x_2, \ldots, x_K\}$, definiamo:

$n_k$ è frequenza assoluta del livello/label $x_k$
questo è il numero di volte che $X = x_k$ compare nei dati osservati

$f_k = \frac{n_k}{n}$ è frequenza relativa del livello/label $x_k$
questo è un numero in [0,1] che esprime la porzione di campioni osservati per i quali $X = x_k$ .

Nota: posso esprimere le frequenze relative in termini percentuali come $f_k = \frac{n_k}{n} \times 100$

Per costruzione

- $\sum_{k=1}^{K} n_k = n$
- $\sum_{k=1}^{K} f_k = 1$



Notes

**Esempio 1**
Su $n = 5$ unità si osserva $X =$*sesso*, i dati osservati sono

$$\{\texttt{F}, \quad \texttt{F}, \quad \texttt{M}, \quad \texttt{F}, \quad \texttt{F}\}$$

In questo caso abbiamo $K = 2$ labels distinti: $x_1 = \texttt{F}, x_2 = \texttt{M}$. Le frequenze assolute sono

$$n_1 = 4, \quad n_2 = 1, \quad f_1 = \frac{4}{5} = 0.8, \quad f_2 = \frac{1}{5} = 0.2$$

**Esempio 2**
Su $n = 6$ unità si osserva $Y =$*numero di scarpe*, i dati osservati sono

$$\{38, \quad 40, \quad 40, \quad 39, \quad 38, \quad 40\}$$

In questo caso abbiamo $K = 3$ livelli distinti: $x_1 = 38, x_2 = 39, x_3 = 40$.
Le frequenze assolute sono

$$n_1 = 2, \quad n_2 = 1, \quad n_3 = 3$$

$$f_1 = \frac{2}{6} = 0.33, \quad f_2 = \frac{1}{6} = 0.17, \quad f_3 = \frac{3}{6} = 0.5$$



Notes

Possiamo calcolare le frequenze in questo modo per qualsiasi tipo di variabile? Pensiamo al caso in cui $X$ è continua

Consideriamo la variabile $X$=`lfaminc` nel data set *bwght*. ci sono 27 diversi livelli osservati, molti di essi estremamente simili tra di loro. I primi valori osservati sono

$$2.6026900, \quad 2.0149031, \quad -0.6931472, \quad 2.7408400, \quad 3.3141861, \ldots$$

Dividiamo il range in $K$ intervalli di livelli (anche detti classi di livelli o bins), e calcolo le frequenze rispetto al numero di osservazioni in ogni classe di livello.

Questo metodo appartiene ad una classe più generale di *metodi di windowing*: i dati vengono divisi e analizzati in tante piccole *finestre*.



Notes

Problema: come determino queste classi di valori? Approcci:

- Scelgo gli intervalli in modo discrezionale
- Fisso $\Delta$, l'ampiezza dell'intervallo, e determino $K$ di conseguenza
- Fisso $K$ e determino l'ampiezza $\Delta$

Esistono regole *ottimali* per ottenere classi di ampiezza uniforme. Ad esempio il metodo di *Sturge*:

- $K = 1 + \left\lceil \log_2(n) \right\rceil$
- $\Delta = \frac{x_{\max} - x_{\min}}{K}$
- Primo intervallo $\rightarrow [x_{\min}\ ,\ x_{\min} + \Delta]$
  Secondo intervallo $\rightarrow (x_{\min} + \Delta\ ,\ x_{\min} + 2\Delta]$
  ...
  k-esimo intervallo $\rightarrow (\ x_{\min} + (k-1)\Delta\ ,\ x_{\min} + k\Delta\ ]$

**Esempi/Applicazioni $\longrightarrow$ `R` script file**



Notes

Se $K$ non è troppo grande, le frequenze consentono di ottenere una presentazione compatta della distribuzione dei dati

Distribuzione semplice

| $X$ | $n_i$ | $f_i$ |
|---|---|---|
| $x_1$ | $n_1$ | $f_1$ |
| $x_2$ | $n_2$ | $f_2$ |
| $\vdots$ | $\vdots$ | $\vdots$ |
| $x_K$ | $n_K$ | $f_K$ |
| | $n$ | $1$ |

Distribuzione in classi

| $X$ | $n_i$ | $f_i$ |
|---|---|---|
| $x_0 \mid\!-\!\mid x_1$ | $n_1$ | $f_1$ |
| $x_1 \ -\!\mid x_2$ | $n_2$ | $f_2$ |
| $\vdots$ | $\vdots$ | $\vdots$ |
| $x_{K-1} \ -\!\mid x_K$ | $n_K$ | $f_K$ |
| | $n$ | $1$ |

- $X$ è quantitativo, discreto, ed espresso con troppi livelli distinti: potrebbe avere senso a costruire le classi
- ⚠ la suddivisione in classi produce perdita di informazione



Notes

**Esempio:** consideriamo la variabile (continua) `faminc` dal data set `bwght`. Prendiamo $K = 3$ classi uniformi:

| `famic` [$10^3\times$ USD] | $n_i$ | $f_i(\%)$ |
|---|---|---|
| $[0.435, 22]$ | 526 | 37.9 |
| $(22, 43.5]$ | 602 | 43.4 |
| $(43.5, 65.1]$ | 260 | 18.7 |
| | 1388 | 100 |



Notes

**Esempio:** consideriamo la variabile (categoriale/nominale) `male` dal data set `bwght`.

| `male` | $n_i$ | $f_i(\%)$ |
|---|---|---|
| Femmina (=0) | 665 | 47.9 |
| Maschio (=1) | 723 | 52.1 |
| | 1388 | 100 |

**Esempi/Applicazioni $\longrightarrow$ `R` script file**



Notes

# Rappresentazioni grafiche di DU

| **Grafico** | **Tipo di variabile** | | | | |
|---|---|---|---|---|---|
| | Continua | In Classi(*) | Discreta(*) | Ordinale | Nominale |
| stripchart | + | no | no | no | no |
| barplot | no | no | + | + | + |
| piechart | no | no | ni | + | + |
| istogramma | no | + | no | no | no |

**Nota (*):**

- "*In Classi*" include il caso delle variabili continue trasformate in classi, e le variabili discrete che sono espresse con troppi livelli distinti.
- "*Discreta*" include il caso di variabili discrete con un numero ragionevole di livelli distinti.

**Esempi/Applicazioni** $\longrightarrow$ `R` **script file** (stripchart, barplot, piechart)



Notes

Notes