Slide Set 7
Code, Outliers e Robustezza

Pietro Coretto
pcoretto@unisa.it

Corso di

Analisi e Visualizzazione dei Dati (Parte I)

Corso di Laurea in "Statistica per i Big Data" (L-41)
Università degli Studi di Salerno

Versione: 25 marzo 2021 (h11:57)

Notes

Dati: rendimenti (%) giornalieri, per "Nabors Industries Ltd" (mercato S&P500), periodo di contrattazione 2002-2007, $n = 1509$

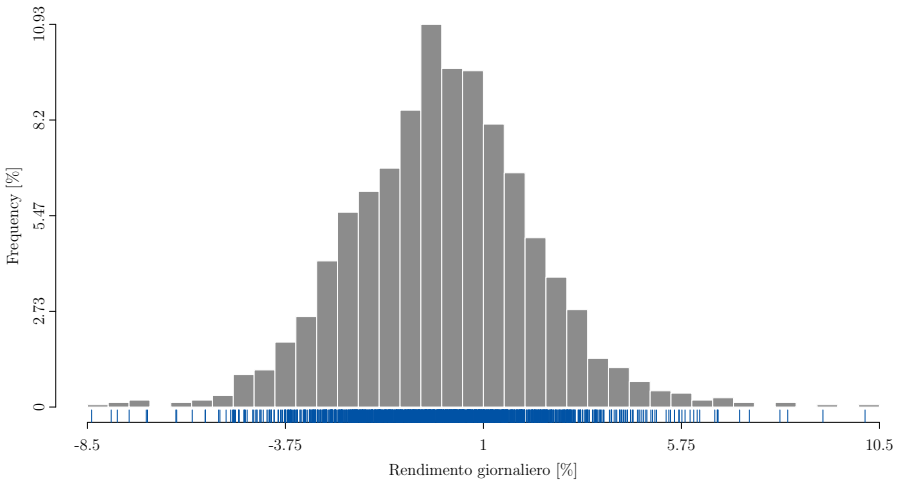

Notes

Dati: rendimenti (%) giornalieri, per "EDS" (mercato S&P500), periodo di contrattazione 2002-2007, $n = 1509$

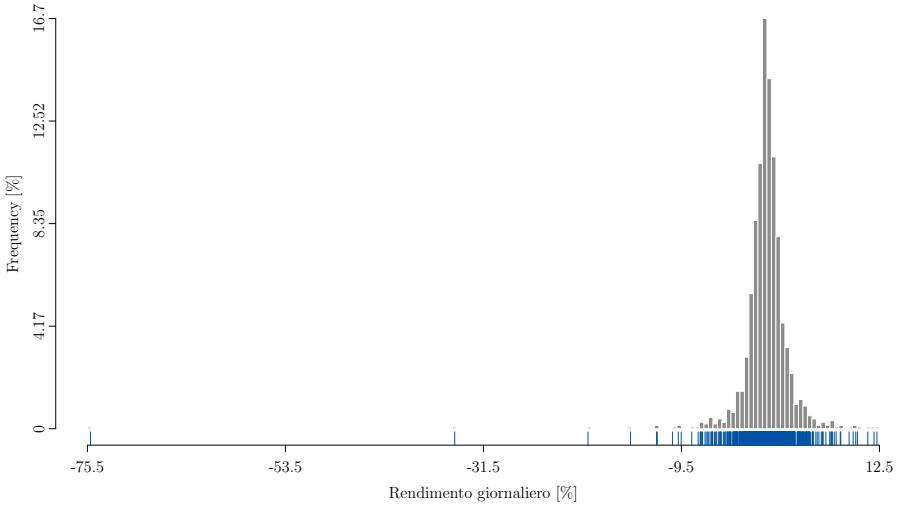

Notes

Dati: rendimenti (%) del capitale proprio (ROE), su $n = 5000$ imprese italiane

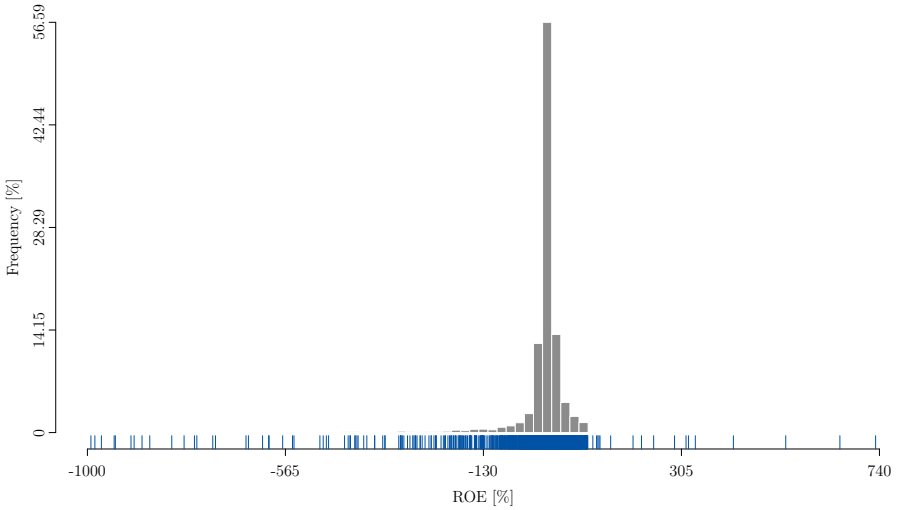

Notes

Dati: assorbimento della potenza elettrica su $n = 329$ contattori, utenze domestiche, fascia oraria 10:30-11:30

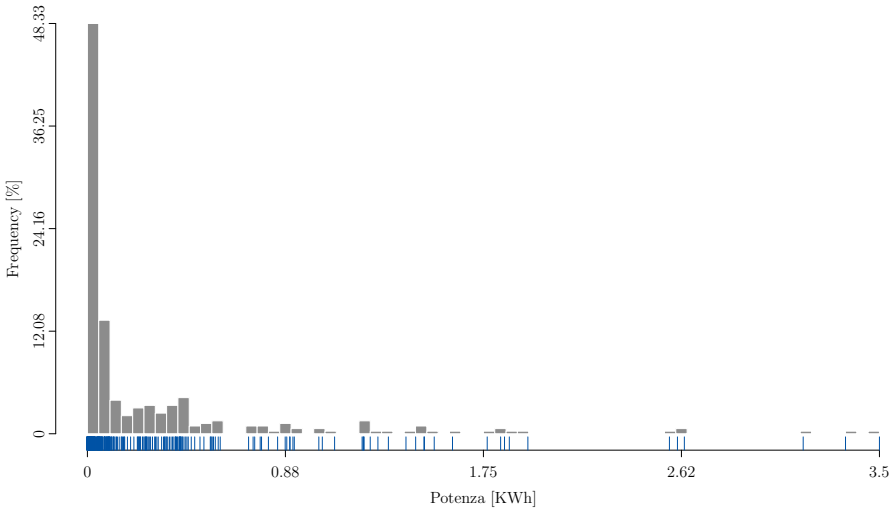

Notes

Code di una distribuzione

è la regione dove si collocano i dati che stanno *lontano* dalla massa centrale. Le code contengono i dati meno frequenti e più estremi

Domanda 1: perché ci interessano le code?

- osservazioni con livelli estremi (anche se sono poche) $\Longrightarrow$ problemi di visualizzazione
- sintesi numeriche (centralità, dispersione, etc) possono diventare poco rappresentative perché fortemente influenzate da una minoranza di punti nelle code

Domanda 2: perché certi dati hanno code così lunghe/estreme?

- questioni intrinseche al processo generatore dei dati (es: potenza, rendimenti)
- artifici introdotti dal meccanismo di misurazione e/o raccolta dati (es: ROE?)

Notes

Curtosi

Curtosi
è una proprietà relativa al velocità con cui la densità/frequenza dei dati diminuisce mano mano che ci allontaniamo dal centro andando verso i valori più estremi

La curtosi è una nozione relativa. Valutazioni circa le code richiedono un riferimento, ovvero un termine di paragone

Assumiamo come riferimento il modello normale standard. Cosa accade se ci spostiamo dal centro verso i valori più estremi?

Notes

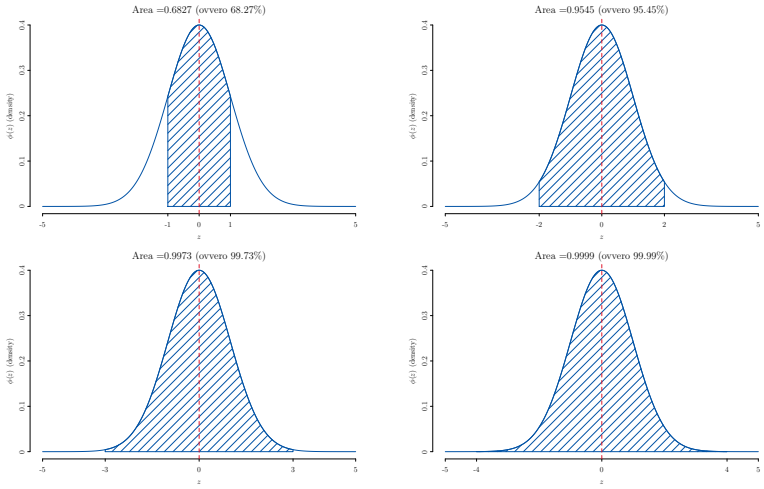

Notes

Proprietà (Curtosi del modello normale standard)

La curtosi del modello normale standard è caratterizzata dal decadimento esponenziale delle code rispetto alla deviazione quadratica dalla media

Osserva: per dati normali standard, ci aspettiamo $\bar{z} = 0$, quindi il quadrato

$$z_i^2 = (z_i - 0)^2 = (z_i - \bar{z})^2$$

coincide con la deviazione quadratica dalla media

Qunado z_i diventa estremo la densità si annulla, infatti

$$\lim_{z_i \to \pm\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2} z_i^2} = 0$$

Nelle code la densità ϕ si annulla ad una velocità paragonabile a

$$e^{-t} \longrightarrow 0 \qquad \text{per} \quad t \longrightarrow \infty$$

dove t rappresenta z_i^2

Notes

Terminologia: quando abbiamo code dense, spesso diciamo

- code spesse/pesanti: code più ricche di dati del solito (si, ma più ricche di cosa?)
- code lunghe: presenza di dati a grande distanza dal bulk (si, ma a che distanza?)

Tipologie di code vs Normale Standard

- Platicurtiche
  code meno spesse/pesanti/lunghe rispetto alla normale standard
- Mesocurtiche o Normocurtiche
  code spesse/pesanti/lunghe come quelle della normale standard
- Leptocurtiche
  code più spesse/pesanti/lunghe rispetto alla normale standard

Valutazione della curtosi: data una variabile osservata X confronto il suo comportamento di coda rispetto al modello normale standard

Notes

Paragonare le code di distribuzioni "*non allineate*" rispetto al loro centro/scaling, non è una buona idea. Dati: IQ

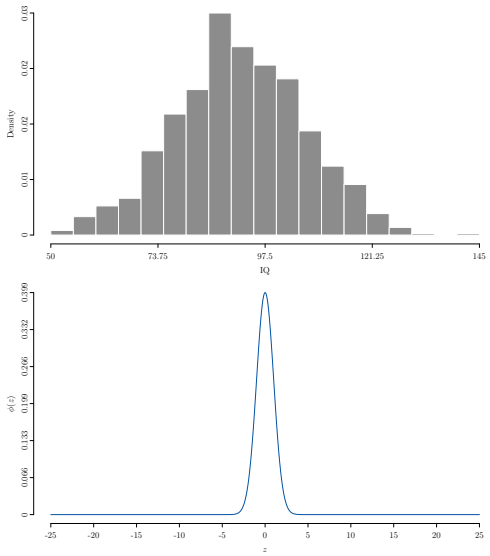

Notes

. . . standardizzando i valori di IQ

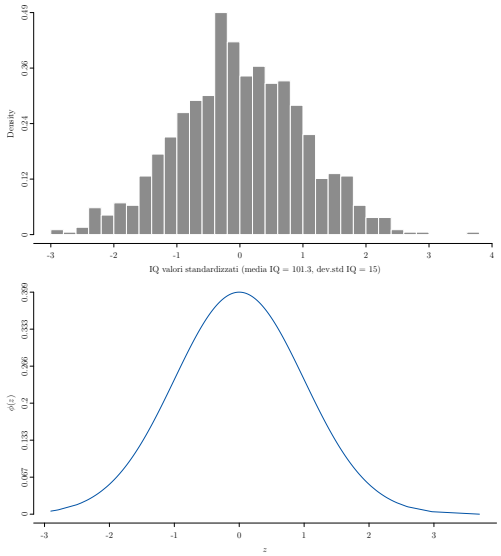

Notes

Le code di X sono le regioni dove si collocheranno i quantili più *esterni*, ovvero quelli calcolati con α lontano da $\alpha = 50\%$. Ad esempio $\alpha = 1\%$, $2\%, 99\%, 98\%, \ldots$

Supponiamo che $\bar{x} = 0$ e $s_X^2 = 1$. X_α è un quantile esterno di X, mentre Z_α è il quantile implicato dal modello normale. Cosa mi aspetto?

- Platicurtiche
  X_α è meno estremo di Z_α
- Mesocurtiche o Normocurtiche
  X_α è approssimativamente uguale a Z_α
- Leptocurtiche
  X_α è più estremo di Z_α

Notes

Normal Quantile-Quantile plot (Normal Q-Q plot)

Supponiamo di voler confrontare le code della X osservata con quelle del modello normale standard. Sia $\{x_1, x_2, \ldots, x_n\}$ il campione osservato e sia Y la standardizzata di X, ovvero

$$y_i = \frac{x_i - \bar{x}}{s_X}, \qquad \text{dove quindi } \bar{y} = 0 \text{ e } s_Y = 1$$

Costruzione del Normal Q-Q plot

- si fissa la griglia di valori per α, solitamente: $\alpha = \frac{1}{n}, \frac{2}{n}, \ldots, \frac{n}{n}$
- si calcolano i quantili di Y per tutti i valori di α
- si calcolano i quantili nella normale standard (detti "*quantili teorici*"), per gli stessi valori di α
- si costruisce un semplice grafico dei quantili di Y vs i "*quantili teorici*"

Notes

Dati IQ

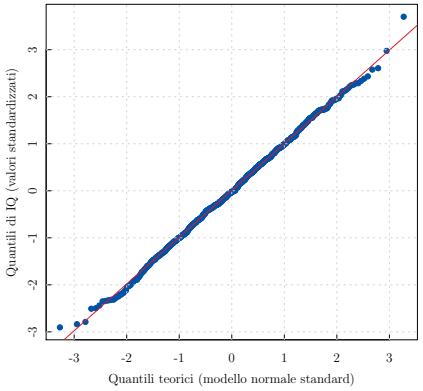

Interpretazione: distribuzione approssimativamente normocurtica. Infatti i quantili di IQ si allineano piuttosto uniformemente a quelli che mi aspetterei sotto il modello normale

Notes

È possibile vedere la scala originale sull'asse verticale

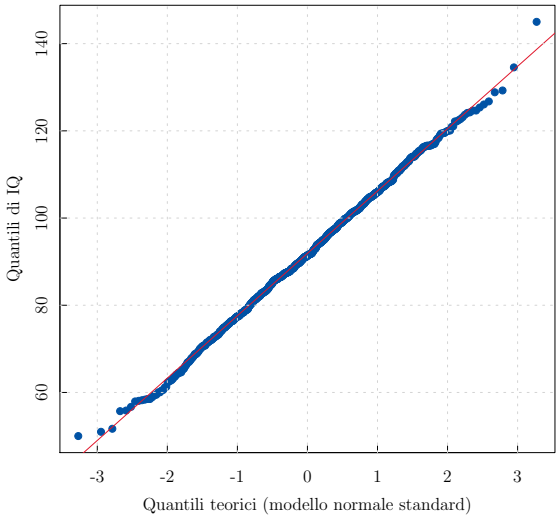

Notes

Dati ROE

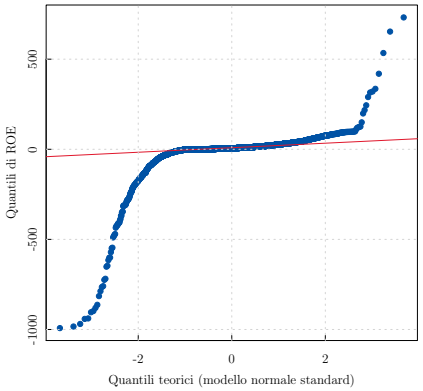

Interpretazione: distribuzione chiaramente leptocurtica. Infatti: (i) sulla coda Sx i quantili sono più estremi della normale (quantili ROE $<$ quantili normale); (i) sulla coda Dx i quantili sono più estremi della normale (quantili ROE $>$ quantili normale)

Notes

Voti esame di Statistica del 25/01/2015:

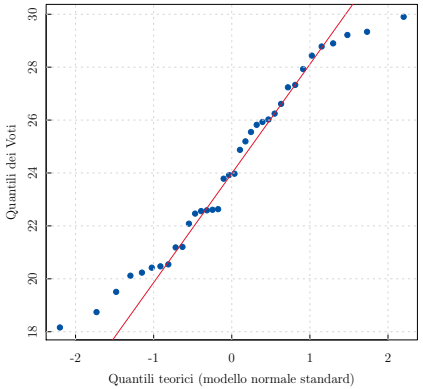

Interpretazione: distribuzione moderatamente platicurtica. Infatti: (i) sulla coda Sx i quantili sono meno estremi della normale (quantili Voti $>$ quantili normale); (i) sulla coda Dx i quantili sono meno estremi della normale (quantili Voti $<$ quantili normale)

Notes

⚠ Il Normal Q-Q plot non consente solo di valutare le code...

Dati: assorbimento della potenza elettrica

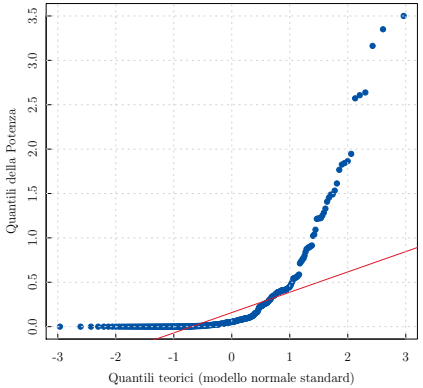

Interpretazione: la distribuzione della potenza devia fortemente dalla forma normale, si vede chiaramente una forte asimmetrica positiva. Infatti: (ii) nella parte centrale il comportamento devia dalla normalità; (ii) la coda Dx molto più spessa della normale (iii) la coda Sx molto meno spessa della normale

Notes

Quantile-Quantile plot (Q-Q plot)

Supponiamo di osservare due variabili U e W. Supponiamo di voler confrontare le loro distribuzioni usando l'idea del Normal QQ-plot.

Costruzione del Q-Q plot

- si fissa la griglia di valori di α, solitamente: $\alpha = \frac{1}{n}, \frac{2}{n}, \ldots, \frac{n}{n}$
- si calcolano i quantili della standardizzata di U per tutti i valori di α
- si calcolano i quantili della standardizzata di W per tutti i valori di α
- si costruisce un semplice grafico dei quantili di U vs i quantili di W

Notes

Dati: tassi di rendimento giornaliero (%), confronto della distribuzione dei rendimenti di NBR vs i rendimenti di EDS

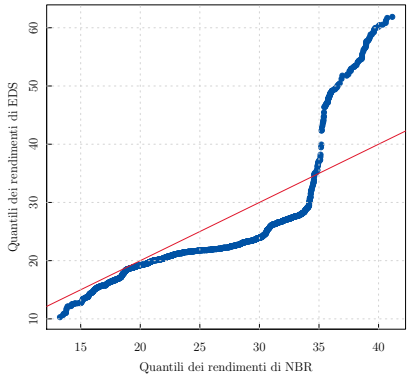

Interpretazione: le due distribuzioni sono molto diverse in ogni parte. I rendimenti di EDS hanno code molto più spesse di NBR, con una differenza enorme sulla coda Dx. Quindi i rendimenti di EDS si caratterizzano per una sovrabbondanza di deviazioni sopra la media

Notes

Eccesso di curtosi

Se i dati $\{z_1, z_2, \ldots, z_n\}$ avessero una distribuzione approssimativamente normale

$$\frac{1}{n}\sum_{i=1}^{n} z_i^4 \approx 3$$

Sia $\{x_1, x_2, \ldots, x_n\}$ il campione osservato allora si definisce eccesso (rispetto al modello normale) di curtosi la quantità

$$g_2 = \left(\frac{1}{n}\sum_{i=1}^{n}\left(\frac{x_i - \bar{x}}{s_X}\right)^4\right) - 3$$

- $g_2 > 0$: evidenza di leptocurtosi
- $g_2 \approx 0$: evidenza di normocurtosi
- $g_2 < 0$: evidenza di platicurtosi

⚠ In caso di distribuzioni multimodali/asimmetriche l'interpretazione di g_2 non è così chiara

Esempi/Applicazioni $\longrightarrow$ `R` **script file**

Notes

Contaminazione dei dati e code pesanti

Contaminazione dei dati

i dati sono misurati e/o acquisiti con errori grossolani. Esempi:

- si misura l'altezza di un individuo in metri, invece di leggere/registrare 1.8 si registra 180
- si misura la pressione di un gas ad una certa temperatura, ma il sistema refrigerante del laboratorio è guasto

La condizione comune in questi esempi è che l'esistenza di dati "*anomali*" è determinata da fattori estranei al meccanismo generatore dei dati.

Outliers

dati estranei al meccanismo che governa X, essi sono anomali / atipici / disomogenei rispetto al bulk

Notes

Dati: "*Galton's height data*", $n = 898$ soggetti

Altezza media $= 1.7583$mt Altezza Mediana $= 1.7577$mt

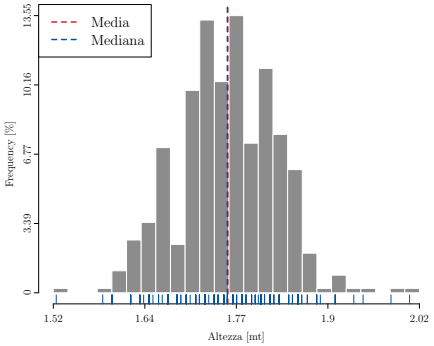

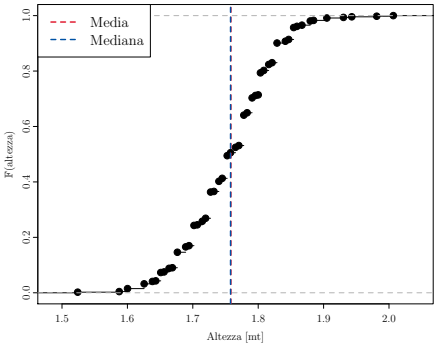

Notes

Supponiamo che in un caso 1.8mt sia stata registrata come 180

Altezza media $=$2.1415mt Altezza Mediana $=$ 1.7577mt

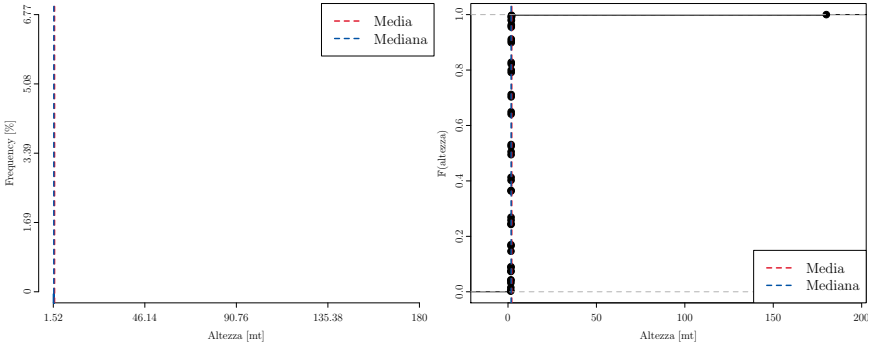

Notes

Dati: "*Air Quality Data*", $n = 31$ misurazioni della concentrazione di varie sostanza nell'aria in Roosevelt Island (NYC, USA).

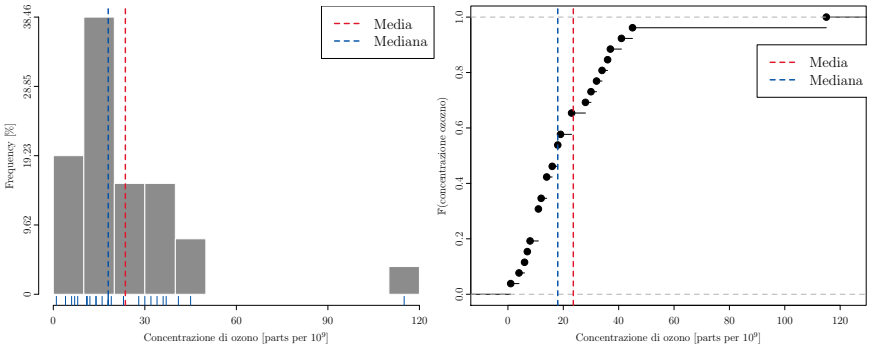

Notes

Gli outliers giacciono nelle code

gli outliers si presentano come valori grandi/piccoli rispetto al bulk, quindi rendono le code dei dati osservati pesanti

Un punto lontano dal *bulk* è sempre un outlier?

Risposta: assolutamente NO. Talvolta le code pesanti sono dovute alla natura del fenomeno (es: certi rendimenti finanziari). La difficoltà di distinguere le due cose è tanto maggiore quanto minore è n.

Esistono metodi per identificare gli outliers con certezza?

Risposta: assolutamente NO. Esistono metodi detti "*robusti*" che consentono di

- ridurre l'influenza delle code pesanti
- identificare punti che sono *potenziali* outliers

Notes

Metodi robusti

Robustezza

è la proprietà di *stabilità* di una procedura di analisi il cui risultato non cambia troppo quando una parte dei dati osservati è sottoposta ad una perturbazione

I metodi robusti sono utili per

- tenere sotto controllo l'effetto di outliers
- identificare i *potenziali* outliers
- in dati non contaminati, ma con code pesanti, tenere sotto controllo l'eccessiva influenza delle code quando n è modesto

Cosa qualifica la *robustezza* di un metodo? Esistono varie misure di robustezza

Notes

Definizione (Finite Sample Replacement Breakdown Point, *informale*)

Il breakdown point (BP) di una procedura di analisi è pari alla minima frazione di dati osservati che arbitrariamente perturbati rendono i risultati dell'analisi privi di qualsiasi senso

Osserva

- Il BP è una misura di *stabilità* rispetto a perturbazioni dei dati osservati
- BP=basso $\implies$ procedure molto sensibili alle perturbazioni dei dati
- BP=alto $\implies$ procedure molto resistenti alle perturbazioni dei dati
- Se gli outliers dovessero superare il 50% di n, questi costituirebbero la maggioranza. Quindi BP=50% è considerato il massimo desiderabile.

Notes

Proprietà (BP di media e mediana)

Sia $\{x_1, x_2, \ldots, x_n\}$ il campione osservato per una variabile X:

1. il BP della media è $\frac{1}{n}$
2. il BP della mediana è $\frac{1}{n}\left\lfloor\frac{n+1}{2}\right\rfloor$

Dimostrazione. Consideriamo prima il caso della media

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{x_1 + x_2 + \ldots, x_{n-1}}{n} + \frac{x_n}{n}$$

cambiamo arbitrariamente $x_n \to \pm\infty$, di conseguenza $\bar{x} \to \pm\infty$. Quindi perturbando arbitrariamente 1 sola osservazione su n, $\bar{x}$ lascia il range dei dati arbitrariamente. Quindi il BP di $\bar{x}$ è $1/n$.

Notes

Passiamo alla mediana. Consideriamo le $h = \left\lfloor \frac{n}{2} \right\rfloor$ più piccole della mediana

$$\underbrace{x_{(1)}, x_{(2)}, \dots x_{(h)}}_{\left\lfloor \frac{n}{2} \right\rfloor \text{ osservazioni}} < X_{0.5} \leq \underbrace{x_{(h+1)}, x_{(h+2)}, \dots, x_{(n)}}_{n - \left\lfloor \frac{n}{2} \right\rfloor \text{ osservazioni}}$$

Perturbiamo arbitrariamente $x_{(1)}, x_{(2)}, \dots x_{(h)} \to -\infty$, la mediana non può cambiare arbitrariamente perché $X_{0.5}$ è ancora nella maggioranza delle osservazioni (non perturbate).

Tuttavia, se la perturbazione riguardasse anche $x_{(h+1)} \to -\infty$, allora $X_{0.5} \to -\infty$

In conclusione devo perturbare almeno $\left\lfloor \frac{n+1}{2} \right\rfloor$ dati per far spostare la mediana arbitrariamente, quindi la frazione di breakdown è $\frac{1}{n} \left\lfloor \frac{n+1}{2} \right\rfloor$

Il ragionamento sulla coda destra dei dati condurrebbe alla stessa conclusione ■

Notes

Osserva

- media: BP$= \frac{1}{n} \to 0$ quando $n \to \infty$
- mediana: BP$= \frac{1}{n} \left\lfloor \frac{n+1}{2} \right\rfloor \to \frac{1}{2}$ (50%) quando $n \to \infty$
- per la mediana già con $n = 20$ otteniamo un BP≈ 0.5

Misure di posizione/centralità robuste

- Mediana
- Trimean
- Medie troncate
- etc

Misure di dispersione robuste

- IQR
- MAD
- etc

Notes

Trimean (BP=25% per n grande)

è un somma pesata di mediana e quartili

$$\text{TM} = \frac{1}{2}\,\text{Med} + \frac{1}{4}Q_1 + \frac{1}{4}Q_3 \tag{7.1}$$

A differenza della mediana rappresenta meglio la parte centrale di distribuzioni asimmetriche

Medie troncate di livello α (BP=α% per n grande)

media sulle $(1-\alpha)n$ osservazioni più centrali ottenute troncando le αn osservazioni più estreme:

- $M = \lceil n\frac{\alpha}{2} \rceil$: numero di punti da troncare su ciascuna coda
- ordinati i dati, si calcola la media delle $n - 2M$ osservazioni centrali

$$\bar{x}_\alpha = \frac{1}{n-2M}\sum_{j=1+M}^{n-M} x_{(j)} \tag{7.2}$$

Notes

Median absolute deviation, noto come MAD (BP=50% per n grande)

è una misura di dispersione definita come la mediana delle deviazioni assolute dalla mediana:

- $\text{Med}(X) = \text{Med}(\{x_1, x_2, \ldots, x_n\})$
- per ogni x_i calcoliamo la deviazione assolute dalla mediana δ_i ovvero

$$\delta_1 = |x_1 - \text{Med}(X)|\,,\ \ldots\ ,\delta_n = |x_n - \text{Med}(X)|$$

- calcoliamo il MAD come la mediana delle deviazioni

$$\text{Mad}(X) = \text{Med}\,\{\delta_1, \delta_2, \ldots, \delta_n\}$$

⚠ per questioni che non possiamo introdurre in questo corso, il MAD viene solitamente moltiplicato per una costante. Solitamente

$$\text{Mad}(X) = 1.4826 \times \text{Med}\,\{\delta_1, \delta_2, \ldots, \delta_n\}$$

Notes

Considerazioni finali sulla robustezza

- la robustezza è una questione fondamentale soprattutto nell'era dei Big Data
- la letteratura sulle tecniche *robuste* ad alto BP è enorme
- un alto BP si ottiene solo riducendo il peso attribuito alle code (pensiamo alla media troncata). Questo ha un costo che sarà chiaro nei corsi successivi
- sebbene le procedure ad alto BP nascono per risolvere problemi di contaminazione/outliers, esse sono utilizzate anche per *stabilizzare* l'analisi in caso di code pesanti e poche osservazioni (n modesto)

Esempi/Applicazioni $\longrightarrow$ R script file

Notes

Identificazione degli outliers

Si stabilisce una regola di classificazione in base alla quale un punto viene "*sospettato di essere un outlier*"

La regola si deve basare su strumenti di provata robustezza, altrimenti la regola stessa sarebbe affetta da contaminazione

Non ci sono essere certezze su cosa sia "*veramente estraneo ai dati*", soprattutto quando n è modesto. L'identificazione deve essere piuttosto interpretata come l'"*attribuzione di un flag ad un dato sospetto*" (J. W. Tukey, 1977)

Notes

Tukey fences

regola di identificazione semplicissima introdotta da Tukey, si basa semplicemente sui quartili e Q_1, Q_3 ed il corrispondente IQR.

Step 1:
sui dati $\{x_1, x_2, \ldots, x_n\}$, calcoliamo Q_1 e Q_3, e $\mathrm{IQR} = Q_3 - Q_1$

Step 2:
fissato un numero $k > 1$, calcoliamo l'intervallo $[H_{\inf}, H_{\sup}]$ dove

$$\begin{aligned} H_{\inf} &= Q_1 - k\,\mathrm{IQR} \\ H_{\sup} &= Q_3 + k\,\mathrm{IQR} \end{aligned}$$

questi sono detti "fences" (recinti) nel linguaggio di Tukey

Step 3:
i dati sospetti sono quelli esterni al "*recinto*" $[H_{\inf}, H_{\sup}]$

Notes

Classificazione

- Punti regolari: le osservazioni che stanno dentro
$$[Q_1 - 1.5\,\mathrm{IQR}\ ,\ Q_3 + 1.5\,\mathrm{IQR}] \qquad (k = 1.5)$$
- (sospetto) outlier: l'osservazione che sta esternamente a
$$[Q_1 - 1.5\,\mathrm{IQR}\ ,\ Q_3 + 1.5\,\mathrm{IQR}] \qquad (k = 1.5)$$
- (sospetto) gross outlier: l'osservazione che sta esternamente a
$$[Q_1 - 3\,\mathrm{IQR}\ ,\ Q_3 + 3\,\mathrm{IQR}] \qquad (k = 3)$$

Domanda: perché $k = 1.5$ e $k = 3$? Si dimostra che se i dati avessero una distribuzione simile a quella normale allora

- circa 97.5% delle osservazioni centrali starebbero dentro
$$[Q_1 - 1.5\,\mathrm{IQR}\ ,\ Q_3 + 1.5\,\mathrm{IQR}]$$
- circa 99.99% delle osservazioni centrali starebbero dentro
$$[Q_1 - 3\,\mathrm{IQR}\ ,\ Q_3 + 3\,\mathrm{IQR}]$$

Notes

Esempio: si osserva

$$\{-10, 10, 11, 5, 8, 9, 16\}$$

da cui $Q_1 = 6.5$, $Q_2 = \mathrm{Med} = 9$, $Q_3 = 10.5$, e $\mathrm{IQR} = Q_3 - Q_1 = 4$

Calcoliamo i "fences" per identificare outliers:

$$[Q_1 - 1.5\,\mathrm{IQR},\ Q_3 + 1.5\,\mathrm{IQR}] = [0.15,\ 16.5]$$

sono sospetti outliers i punti esterni, quindi $X = -10$

Calcoliamo i "fences" per identificare i gross outliers:

$$[Q_1 - 3\,\mathrm{IQR},\ Q_3 + 3\,\mathrm{IQR}] = [-5.5,\ 22.5]$$

sono sospetti gross outliers i punti esterni, quindi ancora una volta $X = -10$

Esempi/Applicazioni $\longrightarrow$ R script file

Notes

Notes