Versione documento: 28 dicembre 2019, h16:00

Università degli Studi di Salerno
Laurea in Management e Informatica

STATISTICA COMPUTAZIONALE
Pietro Coretto

ESERCIZI

Indicazioni generali

- Questi esercizi sono essenziali e complementari allo svolgimento delle lezioni in aula/laboratorio. Lo studente che saprà risolvere questi esercizi in autonomia non avrà nessun problema negli esami di valutazione.
- In generale non ci sarà una sistematica verifica/correzione di questi esercizi. È interesse dello studente accertarsi che la sua preparazione sia adeguata al livello di difficoltà proposto in questo documento. Tuttavia, alcuni di questi problemi possono essere usati durante le lezioni come casi didattici.
- È innegabile che alcuni di questi esercizi sono ispirati a libri e/o risorse in rete. Prima di cercare l'aiuto del docente, oppure quello di libri e *web*, è importante aver fatto ogni possibile sforzo per produrre una soluzione ragionevole.
- Lo schema degli esercizi segue il syllabus del corso, pertanto i problemi presentati vanno risolti nell'ordine proposto.
- La notazione segue quella delle lezioni in assenza di altre indicazioni.
- Con R si indica l'ambiente di sviluppo "R". Con foo() si intente una funzione di R chiamata foo.
- Si consiglia di svolgere ogni esercizio in un file separato cercando di seguire un qualche ordine/convenzione nell'organizzazione dei files. Ordine e sistematica conformità ad uno standard, sono requisiti essenziali per essere produttivi. Esempio: si crea *sistematicamente* il file `ex_x_y.R` per risolvere l'"Esercizio x.y".
- Gli esercizi contrassegnati con ($\star$) saranno svolti in classe da uno studente scelto generalmente a caso.
- "*Errare humanum est, perseverare autem diabolicum*": errori, omissioni ed ambiguità vanno segnalati a e-mail: pcoretto@unisa.it.

Indice

1 R: strutture dati e loro manipolazioni elementari **1**

Esercizio 1.1 (⋆) 1

Esercizio 1.2 1

Esercizio 1.3 (⋆) 2

Esercizio 1.4 2

2 R: data input/output **3**

Esercizio 2.1 3

Esercizio 2.2 (⋆) 4

3 R: uso elementare del device grafico **5**

Esercizio 3.1 5

Esercizio 3.2 (⋆) 5

4 R: strutture di controllo e programmazione **6**

Esercizio 4.1 6

Esercizio 4.2 (⋆) 6

5 Analisi e visualizzazione di distribuzioni univariate **7**

Esercizio 5.1 7

Esercizio 5.2 8

Esercizio 5.3 (⋆) 8

Esercizio 5.4 9

Esercizio 5.5 9

Esercizio 5.6 10

6 Posizione e dispersione **10**

Esercizio 6.1 10

Esercizio 6.2 (⋆) 11

Esercizio 6.3 11

Esercizio 6.4 12

7 Analisi multivariata **12**

Esercizio 7.1 ($\star$) 12

Esercizio 7.2 13

8 Probabilità e metodi Monte Carlo **14**

Esercizio 8.1 14

Esercizio 8.2 ($\star$) 14

Esercizio 8.3 14

9 Modelli di regressione ed inferenza **15**

Esercizio 9.1 15

Esercizio 9.2 ($\star$) 16

Esercizio 9.3 16

10 Metodi di resampling **17**

Esercizio 10.1 ($\star$) 17

Esercizio 10.2 18

1 R: strutture dati e loro manipolazioni elementari

Esercizio 1.1 ($\star$) Creare in R il vettore x contenente i valori (nell'ordine)

$$\{2, 7, 21, 54, -100, 0, 0, 1\}$$

Risolvere i seguenti punti.

1. Calcolare la somma degli elementi del vettore x.
2. Calcolare la somma dei quadrati degli elementi di x.
3. Trovare gli indici degli elementi di x che sono negativi.
4. Trovare gli indici degli elementi di x che sono positivi.
5. Creare il vettore x2 ottenuto eliminando i primi tre elementi di x.
6. Creare il vettore x3 formato dagli elementi positivi di x.
7. Contare gli elementi di x che sono maggiori 20 in valore assoluto.
8. Determinare la posizione dell'elemento massimo di x.
9. Determinare la posizione dell'elemento minimo di x.
10. Calcolare il massimo valore contenuto in x.
11. Calcolare il minimo valore contenuto in x.

* * *

Esercizio 1.2 Considera le seguenti matrici

$$\boldsymbol{X} = \begin{pmatrix} 6 & 4 & 19 & 20 \\ 8 & 14 & 1 & 10 \\ 11 & 15 & 3 & 5 \\ 16 & 9 & 2 & 7 \end{pmatrix}, \qquad \boldsymbol{Y} = \begin{pmatrix} 5 & 10 & 6 \\ 9 & -7 & -6 \\ -3 & -1 & -10 \\ 3 & -9 & 2 \end{pmatrix}. \tag{1.2.1}$$

1. In R costruisci le due matrici assegnandole ad X e Y.
2. Selezionare l'elemento di posizione $(1, 2)$ nella matrice X, e l'elemento di posizione $(4, 2)$ nella matrice Y.
3. Selezionare la prima colonna di X e la seconda riga di Y.
4. Calcolare le matrici: (a) XX contente i quadrati degli elementi di X; (b) logX contente i logaritmi naturali degli elementi di X; (c) sqrtX contente la radice quadrata degli elementi di X.
5. Calcolare: (a) il prodotto matriciale $\boldsymbol{XY}$; (b) la matrice $\boldsymbol{X}^\top\boldsymbol{X}$; (c) $\det(\boldsymbol{X})$ e $\boldsymbol{X}^{-1}$; (d) $\det(\boldsymbol{X}^\top\boldsymbol{X})$ e $(\boldsymbol{X}^\top\boldsymbol{X})^{-1}$.
6. Dalla matrice $\boldsymbol{Y}$ estrarre la sotto-matrice quadrata ottenuta eliminando l'ultima riga.

7. Estrarre la diagonale principale della matrice $\boldsymbol{Y}$.
8. Sostituire la diagonale principale della matrice $\boldsymbol{Y}$ con un il vettore nullo $(0, 0, 0, 0)^{\mathsf{T}}$.
9. Nella matrice $\boldsymbol{Y}$ sostituire tutti i numeri negativi con 0.

Esercizio 1.3 ($\star$) Il giorno 25/12/2018 il team della "DATABOH Srl" si reca presso il campus di UniSA per effettuare una rilevazione sullo stato delle carriere accademiche. In un campione scelto a caso si rilevano i seguenti dati.

Id	**Sex**	**Ofa**	**Mes**	**Nes**
AX12	M	0	24.3	4
BZ55	F	1	na	na
CW32	F	0	28.5	1
DQ55	M	1	na	0

Dove:

Id: identificativo univoco dello studente;

Sex: =M se maschio; =F se femmina;

Ofa: =1 se lo studente è stato immatricolato con debiti formativi; =0 altrimenti;

Mes: media degli esami superati;

Nes: numero di esami superati.

1. Chi sono le unità statistiche? Quali e quante sono le variabili rilevate?
2. Classifica le variabili rispetto al loro *espressione*.
3. Classifica questo data set rispetto al *ruolo delle unità statistiche*.
4. In R costruisci un data.frame() chiamato stud contenente il data set. Usa la risposta al punto precedente ed assicurati che le variabili siano adeguatamente formattate (tipo numerico, metadati, etc.).
5. Rispetto alla variabile **Nes**, estrai gli indici delle osservazioni (anche detti *sample points*) per le quali è stato registrato un valore mancante (na).
6. Rispetto alla variabile **Mes**, estrai gli indici delle osservazioni che non presentano una risposta mancante.
7. Estrai i codici identificativi (**Id**) degli studenti che non hanno risposto alla domanda sulla media degli esami superati.

* * *

Esercizio 1.4 Costruire la seguente lista chiamata LaPrimaLista:

```
> LaPrimaLista
$id
[1] "AA A"  "BBB"  "CCC"   "AAA"   "AAA"   "CCC"   "BBB"   "ZZZ"

$x
[1] -0.6  0.2 -0.8  1.6  0.3 -0.8  0.5

$mat
     [,1] [,2] [,3] [,4]
[1,]   16    7    8    1
[2,]   10   12    2   19
[3,]   13   14   18    6
[4,]   17    3    4   11
```

dove l'elemento LaPrimaLista$mat è un 2D-array. Nota che nella prima posizione del primo elemento della lista va inserito intenzionalmente "AA A" e non "AAA" (vedi ultimi due punti sotto).

1. Estrai dalla lista il suo primo elemento usando prima $ e poi il selettore [[ ]].
2. Estrai il terzo elemento della lista eliminando l'ultima riga e la seconda colonna .
3. Nel primo elemento della lista sostituisci "ZZZ" con "AAA".
4. Nel primo elemento della lista conta quante volte compare "AAA".
5. Nel primo elemento della lista elimina tutti gli spazi tra i caratteri.
6. Adesso conta nuovamente quante volte compare "AAA".

2 R: data input/output

Esercizio 2.1 Considera il seguente data set.

Dati: http://www.decg.it/pcoretto/datasets/crime2005.csv

Descrizione: http://www.decg.it/pcoretto/datasets/crime2005_README.txt

1. Scarica il data set in una directory locale del tuo computer. Leggi la documentazione (`crime2005_README.txt`)
2. Il data set è un file a codifica testuale con formato "*comma-separated-value*". Leggi il data set in R importandolo in un data.frame
3. Verifica la codifica delle variabili. Formatta adeguatamente il tipo numerico di tutte le variabili in funzione della loro natura statistica. Presta particolare attenzione alle variabili di tipo non numerico.
4. Esporta il tuo data.frame opportunamente formattato in un file .RData. Apri una nuova sessione di R e prova a leggere il file appena creato.
5. Esporta il dati in un file a codifica testuale con formato "*tab-separated-values*". Salva il file con estensione .tsv. Apri una nuova sessione di R e prova a leggere il file appena creato.

6. Conta quanti stati hanno un tasso criminale (MU) contenuto tra 5 e 10.
7. Estrai la lista degli stati in cui il tasso criminale è contenuto tra 5 e 10.
8. Conta in quanti stati la percentuale di "white people" (WH) è inferiore al 70%.
9. Estrai la lista degli stati con percentuale di "white people" inferiore al 70%.
10. Conta quanti stati hanno un tasso criminale contenuto in [5 , 10] e percentuale di "white people" inferiore al 70%.
11. Estrai la lista degli stati che hanno un tasso criminale contenuto in [5 , 10] e percentuale di "white people" inferiore al 70%.

* * *

Esercizio 2.2 ($\star$) Considera il seguente data set.

Dati: http://www.decg.it/pcoretto/datasets/apple_data.RData

Descrizione: http://www.decg.it/pcoretto/datasets/apple_data_README.txt

1. Scarica il data set in una directory locale del tuo computer. Leggi la documentazione in (`apple_data_README.txt`).
2. Il file contiene un data.frame chiamato dat. Ispeziona la struttura del data.frame ed accertati che tutte le variabili siano formattate correttamente.
3. Esporta il data set in un file a codifica testuale con formato "*comma-separated-value*". Per verificare la corretta scrittura dei dati importali nuovamente in un data.frame chiamato dat2.
4. Esporta il data set in un file a codifica testuale con formato "*tab-separated-value*". Per verificare la corretta scrittura dei dati importali nuovamente in un data.frame chiamato dat3.
5. Conta il numero di righe (imprese produttrici di mele). Conta il numero di variabili/features misurate.
6. Verifica la presenza di NA nei dati. Fai l'attachment del data.frame.
7. Estrai gli indici delle imprese (righe del data set) per le quali la quantità di mele prodotte (qApples) è maggiore o uguale a 3.
8. Conta il numero di imprese che hanno un costo del lavoro (vLab) compreso tra 50000 e 100000. Quale è la percentuale di queste imprese?
9. Seleziona i costi del capitale (vCap) per tutte le imprese la cui quantità prodotta (qApples) è maggiore o uguale a 3.
10. Calcola la percentuale di imprese che hanno un costo del capitale tra 50000 e 100000, ed un costo del lavoro tra 140000 e 260000.
11. La funzione download.file() consente di scaricare file remoti. Prova il seguente esempio.

```r
## Verifichiamo la directory di lavoro
getwd()

## Verifichiamo il contenuto della directory di lavoro
dir()


## Scarichiamo il file remoto, salvandolo come file locale chiamato
## "xxx.Rdata"
download.file(url="http://www.decg.it/pcoretto/datasets/apple_data.RData",
              dest = "xxx.RData")

## Verifichiamo che il file "xxx.RData" sia stato salvato correttamente
## nella directory di lavoro
dir()
```

3 R: uso elementare del device grafico

Esercizio 3.1 Costruire il vettore

```r
v <- c(9, 1 , -1,8 , 10 , 14,  17 , -5,  -10, 12)
```

1. Visualizza i valori di v contro l'indice della loro posizione nel vettore. Usa la funzione plot() con t="p".
2. Ripeti il punto precedente facendo variare i parametri pch, col, main, xalb, ylab, xlim, ylim.
3. Calcola il vettore u = v**2. Rappresenta v sull'asse orizzontale e u sull'asse orizzontale usando t = "p". Fai qualche esperimento variando i parametri cex, pch, col.
4. Ripeti il punto precedente con t = "l" producendo una linea di spessore 3pt. Ha senso questo tipo grafico? Individua quale è la causa della strana visualizzazione ottenuta.

* * *

Esercizio 3.2 ($\star$) Si consideri la funzione $y = \log(x)$

1. Genera una sequenza di valori per x nell'intervallo $[0.01,\ 10]$. Per i valori generati calcola y in in un vettore y.
2. Produci il grafico della funzione limitando entrambi gli assi (verticale e orizzontale) all'intervallo [0,1]. Nomina opportunamente gli assi e ed il titolo del grafico.
3. Aggiungi al grafico una retta orizzontale tratteggiata di colore grigio passante per il punto $y = 1$. Inoltre, aggiungi una retta verticale di colore grigio passante per il punto $x = 2.718282$.

4. Aggiungi al grafico una retta di colore rosso di equazione $y = x$ (cosiddetta retta a 45 gradi).
5. Aggiungi sullo stesso device il grafico della funzioni $y = \sqrt{x}$.
6. Esporta il grafico nei formati jpeg, png, e pdf

4 R: strutture di controllo e programmazione

Esercizio 4.1 Si consideri la funzione

$$f(n) = \sum_{i=1}^{n} \exp(i),$$

dove i e n sono i numeri interi, e exp la funzione esponenziale, ovvero $\exp(i) = e^i$ Risolvi i seguenti problemi senza usare funzioni (come sum(), length(), etc.)

1. Calcola $f(10)$ usando un loop while().
2. Calcola $f(100)$ usando un loop for().
3. Ripeti i due punti precedenti per $n = 1000$. Dai una spiegazione per lo strano risultato ottenuto.
4. Ripeti i due punti precedenti aggiungendo nel loop un controllo tale che, se nel corso del loop $f(n) \geq$ .Machine$double.xmax, l'iterazione si arresta e viene visualizzato il seguente messaggio di errore:

```
Spiacente:
  f(1000) assume un valore troppo grande per essere rappresentato su
  questo computer
```

* * *

Esercizio 4.2 ($\star$) Considera il seguente data set.

Dati: http://www.decg.it/pcoretto/datasets/balancesheet.RData

Descrizione: http://www.decg.it/pcoretto/datasets/balancesheet_README.txt

Il file RData contiene un data.frame chiamato dat. I seguenti punti possono essere svolti usando funzioni di alto livello. Tuttavia, per scopi didattici in questo esercizio dovrai lavorare con le le sole strutture di controllo iterativo (for/while). Le iterazioni for e while sono talvolta interscambiabili, scegli tu lo strumento più opportuno se questo non espressamente indicato nella domanda.

1. Importa il data set in una sessione di R. Esplora la struttura dei dati.

2. Con un opportuno loop costruisci il vettore NumCol, dove NumCol[j] =1 se la la j-esima colonna del data set è di tipo *numeric*, NumCol[j] =0 altrimenti. Assegna ad ogni elemento di NumCol il nome della corrispondente colonna di dat.

3. Con un opportuno loop for ottieni il vettore chiamato SumQuadCol, dove SumQuadCol[j] = somma dei quadrati dei valori contenuti nella colonna j-esima di dat se questa contiene un tipo *numeric*, SumQuadCol[j]=NA altrimenti.

4. Ogni unità statistica (riga) è un'impresa del settore alimentare. Le imprese campionate sono $n = 5000$. Considera la variabile `roe`, questo è un importantissimo indice di bilancio che misura la redditività del capitale proprio (vedi https://it.wikipedia.org/wiki/Return_on_equity). Costruisci la matrice RoeDiff, dove RoeDiff[h,k] contiene la differenza in valore assoluto tra il `roe` dell'impresa h e quello dell'impresa k, con $h, k = 1, 2, \ldots, 5000$. Ovvero RoeDiff[h,k] = abs(dat$roe[h] - dat$roe[k]). (Attenzione: nota che in `roe$dat` sono presenti molti NA, NaN)

5. Controlla se la matrice RoeDiff è simmetrica.

6. RoeDiff[h,k] può essere considerata una misura della *diversità* nella redditività di due imprese. Infatti, RoeDiff[h,k] =0 se le imprese h e k hanno lo stesso ROE, RoeDiff[h,k] sarà tanto più grande quanto più ampia è la differenza tra i ROE delle due imprese. Usa un doppio loop for su righe e colonne di RoeDiff per trovare la coppia di imprese più dissimili.

7. Confronta il risultato precedente con l'output dei seguenti comandi

```
which.max(RoeDiff)

max(RoeDiff)

which(RoeDiff == max(RoeDiff , na.rm = TRUE), arr.ind = TRUE)
```

5 Analisi e visualizzazione di distribuzioni univariate

Esercizio 5.1 Considera nuovamente il data set:

Dati: http://www.decg.it/pcoretto/datasets/balancesheet.RData

Descrizione: http://www.decg.it/pcoretto/datasets/balancesheet_README.txt

Il file RData contiene un data.frame chiamato dat.

1. Considera la variabile dat$status. Quale è il tipo di `status` (continua, discreta, ordinale, etc)? Quali e quanti sono i livelli di espressione distinti di status? Filtra i valori mancanti (NA), calcola le frequenze assolute e relative (percentuali) e rappresentale in forma tabellare (distribuzione di frequenze).

2. Considera la variabile dat$empl. Quale è il tipo di `empl` (continua, discreta, ordinale, etc)? Quanti, e quali sono i suoi livelli di espressione distinti? Ha senso trattarla come una variabile discreta? Perché? Da questo punto in poi l'esercizio riguarda esclusivamente `empl`.

3. Trasformare dat$empl in classi di livelli (windowing) con $K = 5$. Calcola il range dei dati e visualizza lo stripchart. Secondo te queste classi hanno senso? Cosa succede?

4. Adesso fissiamo $K = 4$, e fissiamo le classi di livelli in modo discrezionale come segue:

$$[0, 10] \quad (10, 50] \quad (50, 250] \quad (250, \infty)$$

   Intuitivamente, ritieni che queste classi siano più appropriate di quelle ottenute al punto 4 e 5? La scelta è discrezionale, ma trova fondamento nella nelle classificazioni standard (vedi: https://it.wikipedia.org/wiki/Piccola_e_media_impresa). Usa la funzione cut() controllando l'argomento breaks in modo adeguato per ottenere la suddivisione di dat$empl nelle quattro classi indicate sopra. Usa la funzione table() ed ottieni la corrispondente distribuzione di frequenze assolute e relative.

* * *

Esercizio 5.2 Considera i dati dell'Esercizio 5.1.

1. Per la variabile dat$status calcola le frequenze assolute, le frequenze relative, e le frequenze relative percentuali.

2. Rappresenta la distribuzione di frequenze calcolata nei punti precedenti con tutte le rappresentazioni grafiche che ritieni appropriate.

3. Considera la variabile dat$curr. Rappresenta la sua sua distribuzione con i grafici che ritieni opportuni. Esporta ognuno di questi grafici in un file .pdf.

* * *

Esercizio 5.3 ($\star$) Considera il data set:

Dati: http://www.decg.it/pcoretto/datasets/balancesheet.RData

Descrizione: http://www.decg.it/pcoretto/datasets/balancesheet_README.txt

Sia Y = `dat$prma` = "*profit margin*". Y è misura in scala percentuale, e misura il margine di profitto dell'impresa, ovvero

$$Y = \frac{\text{Ricavi - Costi}}{\text{Ricavi}} \times 100.$$

In altri termini Y è la percentuale di prezzo di vendita che l'impresa riesce a trasformare in profitto. Per un fissato $\alpha \in [0, 1]$, sia Y_α il quantile di Y al livello α. Si denota inoltre $\mathbb{F}(t)$ il valore della funzione di distribuzione empirica dei dati (ECDF) calcolata nel punto t.

1. Chi sono le unità statistiche in questo data set?

2. Rappresenta graficamente l'ECDF e l'istogramma di Y in un'unica finestra grafica.

3. Focalizza l'attenzione sulla sola ECDF. Guardando il grafico, "*ad occhio*", quanto vale approssimativamente $\mathbb{F}(0)$? Interpreta il risultato.

4. Guardando il grafico dell'ECDF, quanto vale approssimativamente il quantile empirico al livello $\alpha = 0.2$, ovvero $Y_{0.2}$?

5. Adesso calcola $Y_{0.2}$ usando la funzione quantile() e selezionato l'opportuno type. La tua "*approssimazione ad occhio*" del punto precedente era giusta? Interpreta il risultato.

6. Usa la funzione quantile() selezionando il type = 7 (default). Calcola i quantili di Y per i livelli $\alpha = 5\%, 95\%$. Interpreta il risultato. A quale delle due approssimazioni corrisponde il quantile che hai calcolato in questo punto?

* * *

Esercizio 5.4 Usa il data set PlantGrowth disponibile in R base package:

```
data("PlantGrowth")
str(PlantGrowth)
?PlantGrowth
```

1. Calcola i quartili di PlantGrowth$weight.

2. Visualizza uno stripchart() di PlantGrowth$weight. Sullo stesso grafico, usando dei segmenti verticali di colore diverso, indica la posizione di media e mediana. Riporta anche una legenda per la corretta interpretazione dei colori.

3. Visualizza l'istogramma di PlantGrowth$weight. Sullo stesso grafico riporta lo stripchart dei punti usando rug().

4. Visualizza l'ecdf PlantGrowth$weight. Sullo stesso grafico visualizza media, mediana e quartili.

5. Calcola i quartili di PlantGrowth$weight condizionatamene alle categorie di PlantGrowth$group

6. Calcola i decili di PlantGrowth$weight.

7. Calcola i percentili PlantGrowth$weight.

8. Rappresenta la curva dei percentili di PlantGrowth$weight. Sull'asse orizzontale rappresenta il livello del percentile ($\alpha = 1\%, 2\%, \ldots$), sull'asse verticale rappresenta i percentili calcolati al punto precedente.

9. Calcola i percentili di PlantGrowth$weight separatamente per i tre gruppi sperimentali {ctrl, trt1, trt2} indicati nel fattore PlantGrowth$group

10. Rappresenta le curve dei percentili calcolate al punto precedente in un unico grafico (come nel punto 9) usando tre colori diversi ed una legenda per spiegare i colori. Interpreta il grafico ottenuto.

* * *

Esercizio 5.5 Si osserva la variabile X su $n = 10$ unità statistiche:

-33	-30.2	26.2	-17.7	-11.5	28.2	-20.3	-1.2	38	1.6

1. Elenca quali rappresentazioni grafiche sono appropriate per la distribuzione di X. Visualizza lo stripchart.
2. Fai un windowing dei dati con i seguenti intervalli

$$[-33, 0] \quad (0, 15] \quad (15, 38].$$

   Per ciascun intervallo calcola le frequenze relative e le densità, in altri termini calcola l'istogramma dei dati.
3. Visualizza il grafico dell'istogramma.

* * *

Esercizio 5.6 Usa il data set PlantGrowth disponibile in R base package:

```
data("PlantGrowth")
str(PlantGrowth)
?PlantGrowth
```

Sia X = PlantGrowth$weight

1. Visualizza il boxplot di PlantGrowth$weight.
2. Visualizza il boxplot di PlantGrowth$weight condizionando sui i tre gruppi sperimentali {ctrl, trt1, trt2} indicati nel fattore PlantGrowth$group. Commenta il risultato
3. Visualizza l'istogramma di PlantGrowth$weight
4. Visualizza la densità kernel di PlantGrowth$weight usando la larghezza di banda calcolata da R. Prova a variare la larghezza di banda e nota il suo effetto sulla densità stimata.
5. In una sola finestra grafica organizzata in 2 righe 2 colonne visualizza l'istrogramma, la densità kernel, l'ECDF ed il boxplot

6 Posizione e dispersione

Esercizio 6.1 Usa il data set mtcars disponibile in R base package:

```
data("mtcars")
str(mtcars)
?mtcars
```

1. Calcola la media di mtcars$mpg senza usare la funzione mean(). Controlla il risultato usando la funzione mean()

2. Calcola la media di tutte le variabili usando la funzione colMeans(). Ripeti i calcoli usando la funzione apply()

3. Calcola la mediana di mtcars$mpg usando median() e poi quantile().

4. Calcola la mediana di tutte le variabili usando la funzione apply()

5. Produci un istogramma di mtcars$mpg con 5 classi uniformi. Usa l'istogramma per approssimare la Moda dei dati.

6. Tabula le frequenza di mtcars$gear. Calcola la moda.

7. Usa la funzione tapply() per calcolare la media di mtcars$mpg condizionatamente a mtcars$vs=0 e mtcars$vs=1. Ripeti i calcoli usando la mediana al posto della media.

8. Ripeti l'esercizio precedente usando la media troncata al 20% al posto della media campionaria.

9. Ripeti il primo punto indicando sull'istogramma la posizione della media e mediana con due rette di colore diverso. Aggiungi all'istogramma lo stripchart dei punti osservati.

* * *

Esercizio 6.2 ($\star$) Usa il data set USArrests disponibile in R base package:

```
data("USAarrests")
str(USAarrests)
?USAarrests
```

1. Calcola la media di USArrests$Murder. Estrai i nomi degli stati per cui Murder è superiore alla media (nota: in questo caso il nome delle unità campionarie è codificato come rownames())

2. Calcola la mediana di USArrests$UrbanPop e USArrests$Murder. Estrai i nomi degli stati per cui Murder e UrbanPop sono maggiori delle rispettive mediane. Pensando alla geografia degli USA, il risultato ti suggerisce qualche interpretazione?

3. Quale è lo stato più vicino alla media di rape? Quale è lo stato più vicino alla mediana di rape?

4. Calcola media di tutte le variabili. Per ogni variabile trova lo stato più vicino alla media.

5. Calcola la mediana di tutte le variabili. Per ogni variabile trova lo stato più vicino alla mediana.

6. In base ai due punti precedenti, valutando i risultati globalmente, esiste uno stato che è maggiormente vicino alla tendenza centrale delle variabili?

* * *

Esercizio 6.3 Usa il data set PlantGrowth disponibile in R base package:

```r
data("PlantGrowth")
str(PlantGrowth)
?PlantGrowth
```

Sia $X =$ PlantGrowth$weight

1. Calcola la varianza, deviazione standard, e IQR di X senza usare le funzioni var(), sd(), e IQR. Controlla il risultato usando var(), sd(), e IQR.
2. Calcola varianza, deviazione standard, IQR e MAD di X condizionatamente (separatamente) per i tre gruppi sperimentali {ctrl, trt1, trt2} indicati nel fattore PlantGrowth$group.
3. L'unità di misura è l'oncia. Quale trasformazione lineare consente di trasformare i dati in grammi? Applica la trasformazione.

* * *

Esercizio 6.4 Considera il data set:

Dati: http://www.decg.it/pcoretto/datasets/balancesheet.RData

Descrizione: http://www.decg.it/pcoretto/datasets/balancesheet_README.txt

I dati sono contenuti in un data.frame chiamato dat.

1. Costruisci un nuovo data.frame, chiamato X, che contiene solo le variabili roe, roa, solr, prma.
2. Visualizza i boxplot paralleli delle variabili in X. Cosa noti?
3. Standardizza tutte le colonne di X centrando sulla media e scalando per la deviazione standard. Ripeti il punto precedente.
4. Ripeti il punto precedente usando mediana e MAD.
5. Riproduci la standardizzazione dei dati nei punti precedenti usando il la funzione scale()

7 Analisi multivariata

Esercizio 7.1 ($\star$) Considera il data set:

Dati: http://www.decg.it/pcoretto/datasets/galton_height.tsv

Descrizione: http://www.decg.it/pcoretto/datasets/galton_height_README.txt

I dati sono contenuti in un data.frame chiamato dat.

1. I dati sono in formato TSV, importa il data set in una data.frame chiamato dat, e formatta adeguatamente tutte le variabili.
2. Calcola la covarianza e la covarianza e la correlazione tra l'altezza del padre e quella del figlio. Intepreta il risultato.
3. Calcola la covarianza e la correlazione tra l'altezza del padre e quella della madre. Intepreta il risultato.
4. Visualizza su un solo grafico tutti gli scatter a coppie. Interpreta il grafico.
5. Ripeti il punto precedente eliminando le variabili non quantitative.
6. Visualizza il boxplot di dat$Height condizionando sul sesso
7. Visualizza lo scatter di dat$Father contro dat$Height usando colori e simboli diversi per i maschi e le femmine.
8. Visualizza nuovamente il pairs-plot (scatter a coppie) usando colori/simboli diversi per maschi e femmine. Commenta il risultato.

* * *

Esercizio 7.2 Considera il data set:

Dati: http://www.decg.it/pcoretto/datasets/nls80.RData

Descrizione: http://www.decg.it/pcoretto/datasets/nls80_README.txt

I dati sono contenuti in un data.frame chiamato NLS80.

1. Usa la funzione cut() per fare un windowing di iq in 5 classi uniformi.
2. Visualizza la distribuzione di frequenze doppia delle classi di livelli di iq contro la variabile urban.
3. Rispetto al punto precedente calcola anche le frequenze relative percentuali, ed aggiungi le marginali.
4. Sulla base dei punti precedenti stima l'associazione tra iq ed urban usando la statistica χ^2 di Pearson, e la sua versione normalizzata chiamata Φ^2. Interpreta e commenta il risultato.
5. Studia la relazione di dipendenza analizzata in precedenza usando un mosaic-plot. Interpreta e commenta il risultato
6. Usando strumenti numerici e grafici, analizza la l'associazione/dipendenza tra urban e black, e poi tra south e black.

8 Probabilità e metodi Monte Carlo

Esercizio 8.1

1. Sia $X \sim \text{Normale}(5, 7)$, calcolare la $\Pr\{0 \leq X \leq 7\}$ usando la funzione pnorm()
2. Sia $Z \sim \text{Normale}(0, 1)$, $X \sim \text{Normale}(-3, 1)$, e $Y \sim \text{Normale}(3, 1)$. Visualizza su un solo grafico le curve di densità delle tre variabili casuali.
3. Sia $Z \sim \text{Normale}(0, 1)$, $X \sim \text{Normale}(0, 0.5)$, e $Y \sim \text{Normale}(0, 2)$. Visualizza su un solo grafico le curve di densità delle tre variabili casuali.
4. Ripeti i due punti precedenti visualizzando la funzione di distribuzione (cumulata) al posto della densità.
5. Sia $X \sim \text{Poisson}(\lambda = 10)$. Visualizza la funzione di probabilità di massa e la corrispondente funzione di distribuzione (cumulata).
6. Sia $X \sim \text{Binomiale}(n = 10, p = 0.1)$. Visualizza la funzione di probabilità di massa e la corrispondente funzione di distribuzione (cumulata).
7. Sia $X \sim \text{Binomiale}(n = 1000, p = 0.1)$. Visualizza la funzione di probabilità di massa e la corrispondente funzione di distribuzione (cumulata). Cosa noti? Come te lo spieghi?
8. Sia $Z \sim \text{Normale}(0, 1)$, calcola i quantili ai livelli $\alpha = 25\%, 75\%$. Calcola inoltre la differenza interquartile.
9. Calcola l'IQR per $X \sim \text{Normale}(0, \sigma^2)$, per i seguenti valori di $\sigma^2 = \{0.5, 1, 2, 3, 5, 10, 20, 30\}$. Ora rappresenta graficamente i valori dell'IQR contro i valori corrispondenti di σ^2. Cosa noti? Come te lo spieghi?

* * *

Esercizio 8.2 ($\star$) Sia $X \sim \chi^2_5$. Considera la funzione

$$g(X) := \log\left(\frac{1 + X}{\mathrm{E}[X]}\right).$$

1. Usa il metodo Monte Carlo per approssimare $\mathrm{E}[g(X)]$.
2. Usa il metodo Monte Carlo per approssimare $\mathrm{Var}[g(X)]$.

* * *

Esercizio 8.3 In un gioco si puntano 5 Euro e si estraggono a caso senza rimessa 5 carte da un mazzo di carte francesi non truccate (senza Jolly). Il seguente schema di premi si rifà alla terminologia del gioco del poker[1]

[1] https://it.wikipedia.org/wiki/Punti_del_poker

- 5300 Euro se si ottiene una scala reale
- 3812 Euro se si ottiene un poker d'assi
- 442 Euro se si ottiene un poker qualsiasi
- 80 Euro se si ottiene un full
- 10 Euro se si ottiene un tris
- 4.5 Euro se si ottiene una doppia coppia
- 1 Euro se si ottiene una coppia

1. Simula una sola mano del gioco. Quanto hai vinto (premio - puntata)?
2. Costruisci un esperimento Monte Carlo simulando $b = 1000$ volte il gioco. Approssima il valore atteso (media) della vincita.
3. Ripeti il punto precedente usando $b = 1000000$ repliche Monte Carlo. L'approssimazione per il valore atteso della vincita è cambiato di molto?
4. Sulla base dei calcoli precedenti faresti questo gioco? Definiresti questo gioco "*equo*"? Perché?

9 Modelli di regressione ed inferenza

Esercizio 9.1 Considera il data set:

Dati: http://www.decg.it/pcoretto/datasets/nls80.RData

Descrizione: http://www.decg.it/pcoretto/datasets/nls80_README.txt

I dati sono contenuti in un data.frame chiamato NLS80.

1. Calcola un intervallo di confidenza al 95% per la media dell'iq.
2. Fissando il livello di confidenza al livello $\alpha = 5\%$, testare l'ipotesi nulla che la media di iq sia maggiore o uguale a 100.
3. Testare l'ipotesi nulla che il livello di medio di scolarizzazione dei genitori è uguale contro l'ipotesi che è diverso. Si noti che il livello di scolarizzazione dei genitori è misurato dalle variabili feduc e meduc.
4. Sia p_{black} la proporzione di individui afroamericani. Stima un intervallo di confidenza al 90% per p_{black}.
5. Testa l'ipotesi nulla che $p_{\text{black}} \leq 15\%$.

6. Sia $p^{\text{south}}_{\text{black}}$ la proporzione di individui afroamericani che provengono dagli stati del sud, e sia $p^{\text{ns}}_{\text{black}}$ la proporzione di individui afroamericani che non provengono dagli stati del sud. Testare l'ipotesi nulla che $p^{\text{south}}_{\text{black}} = p^{\text{ns}}_{\text{black}}$, contro l'ipotesi alternativa $p^{\text{south}}_{\text{black}} \neq p^{\text{ns}}_{\text{black}}$.

7. Testa l'indipendenza tra black e urban.

8. Utilizzando strumenti grafici verifica la normalità della distribuzione di iq.

9. Utilizza il test di Kolmogov-Smirnov per verificare la normalità della distribuzione di iq.

10. Utilizza il test di Kolmogov-Smirnov per verificare che la distribuzione dell'iq degli individui che vivono al sud è uguale alla distribuzione dell'iq degli individui che non vivono nel sud.

* * *

Esercizio 9.2 ($\star$) Considera il data set:

Dati: http://www.decg.it/pcoretto/datasets/icecream_hildreth_lu.csv

Descrizione: http://www.decg.it/pcoretto/datasets/icecream_hildreth_lu_README.txt

1. Visuallizza il pairs-plot di tutte le variabili. Cosa noti?

2. Stima un modello di regressione lineare

$$\texttt{cons} = \beta_0 + \beta_1 \texttt{income} + \beta_2 \texttt{price} + \beta_3 \texttt{temp} + \text{errore}. \tag{9.2.1}$$

3. Visualizza la diagnostica sulle stime del modello (9.2.1). Commenta i risultati.

4. Fissando un livello di significatività $\alpha = 5\%$, quale delle variabili esplicative hanno un impatto marginale sui consumi non nullo?

5. Usa le stime del del modello (9.2.1) per prevedere il consumo medio atteso di gelati quando income = 79.25, price = 0.27, temp = 32.25.

6. Stima il modello

$$\texttt{cons} = \phi_1 \texttt{income} + \phi_2 \texttt{temp} + \text{errore}. \tag{9.2.2}$$

Come nel caso precedente visualizza la diagnostica, e testa l'ipotesi nulla che l'impatto marginale delle variabili esplicative è nullo.

7. Usa le stime del del modello (9.2.2) per prevedere il consumo medio di gelati quando income = 79.25, temp = 32.25.

8. Usa le stime del del modello (9.2.2) per prevedere la variazione del consumo medio di gelati quando income, aumenta di un 1\$.

9. Usa le stime del del modello (9.2.2) per prevedere la variazione del consumo medio di gelati quando income passa da 83.50\$ a 85\$.

* * *

Esercizio 9.3 Considera il data set:

Dati: http://www.decg.it/pcoretto/datasets/hmda.RData

Descrizione: http://www.decg.it/pcoretto/datasets/hmda_README.txt

I dati sono contenuti nel data.frame dat. Siano $X_1, X_2, \ldots X_k$ le osservate nel campione. Si definisce

$$p = \Pr\{\mathsf{deny} = \mathsf{yes} \,|\, X_1, X_2, \ldots X_k\},$$

la probabilità che il mutuo non viene accordato al cliente, anche detta probabilità di rifiuto del mutuo.

1. Stima il seguente modello logit per spiegare la probabilità di rifiuto

$$\text{logit}(p) = \beta_0 + \beta_1 \texttt{pirat}. \tag{9.3.1}$$

2. Visualizza il summary() della stima precedente. Possiamo concludere che `pirat` ha un impatto statisticamente significativo sull'odds della probabilità di diniego del mutuo? Perché?

3. Stima il seguente modello

$$\text{logit}(p) = \phi_0 + \phi_1 \texttt{pirat} + \phi_2 \texttt{afam}. \tag{9.3.2}$$

   Visualizza il summary() della stima. Possiamo concludere che i due regressori hanno congiuntamente un un impatto statisticamente significativo sull'odds della probabilità di diniego del mutuo? Perché?

4. Usa i risultati della stima precedente per prevedere la probabilità che il mutuo venga accordato ad un individuo afroamericano che riporta un rapporto pagamenti/reddito pari a 0.3

5. Ripeti i calcoli precedenti per un individuo non afroamericano. Interpreta il risultato.

10 Metodi di resampling

Esercizio 10.1 ($\star$) Considera i dati dell'esercizio 9.1. Svolgi i seguenti punti utilizzando la funzione boot() del package library(boot)

1. Calcola un intervallo di confidenza al 95% per la media dell'iq. Confronta il risultato con l'esercizio 9.1.

2. Sia p_{black} la proporzione di individui afroamericani. Stima il bias e lo standard error per la stima di p_{black}.

3. Stima un intervallo di confidenza al 90% per p_{black}. Confronta il risultato con l'esercizio 9.1.

4. Sia $p_{\text{black}}^{\text{south}}$ la proporzione di individui afroamericani che provengono dagli stati del sud, e sia $p_{\text{black}}^{\text{ns}}$ la proporzione di individui afroamericani che non provengono dagli stati del sud. Calcola intervalli di confidenza per $p_{\text{black}}^{\text{south}}$ e $p_{\text{black}}^{\text{ns}}$.

* * *

Esercizio 10.2 Considera i dati dell'esercizio 9.2.

1. Usa la 10-Fold cross-validation per stimare il valore atteso dell'errore di previsione per il modello (9.2.1).
2. Usa la 10-Fold cross-validation per stimare il valore atteso dell'errore di previsione per il modello (9.2.2).
3. Quale dei due modelli riporta la migliore performance previsiva?